Einführung in die Wahrscheinlichkeitsrechnung und Mathematische Statistik

Prof. Dr. Stefan Ankirchner

Sommersemester 2023
Version vom 7. Juli 2023

Inhaltsverzeichnis

I Wahrscheinlichkeitstheorie **2**

0 Einführende Beispiele **2**

1 Ergebnisräume und Ereignisse **3**

2 Laplace-Experimente **5**
2.1 Exkurs: Elemente der Kombinatorik 6
2.2 Modellierung von Laplace-Experimenten mit Variationen und Kombinationen 7
2.3 Lange Sequenzen von Zahl-Würfen 9
2.4 Ausblick 10

3 Wahrscheinlichkeitsmaße **10**

4 Bedingte Wahrscheinlichkeiten **16**

5 Unabhängige Ereignisse **19**

6 Zufallsvariablen und Verteilungen **20**
6.1 Grundlegende Definitionen 20
6.2 Wichtige diskrete Verteilungen 22
6.3 Wichtige absolutstetige Verteilungen 25
6.4 Unabhängige Zufallsvariablen 27

7 Verteilungsfunktionen **29**

8 Erwartungswerte von Zufallsvariablen **32**

9 Varianz und Kovarianz **40**

10 Grenzwertsätze **44**

II Statistik **50**

11 Punktschätzungen **50**
11.1 Die Momentenmethode 51
11.2 Die Maximum-Likelihood-Methode 52
11.3 Bias und mittlerer quadratischer Fehler 55
11.4 Punkt- versus Bereichsschätzer 59

12 Hypothesentests **63**
12.1 Einführende Beispiele 63
12.2 Hypothesentests für Bernoulli-Verteilungen 65

A Tabelle der Normalverteilung **71**

B Tabellen der Binomialverteilung **72**

Empfehlung als begleitende Literatur:

Sheldon Ross. Introduction to Probability Models (2014). Siehe [1].

Teil I
Wahrscheinlichkeitstheorie

0 Einführende Beispiele

Beispiel 0.1. *Mia und Noah werfen immer wieder eine Münze. Jedes Mal wenn Kopf erscheint, bekommt Mia einen Euro von Noah. Bei jedem Zahlwurf bekommt Noah einen Euro von Mia. Annahme: Nach dem ersten Wurf hat Mia einen Euro gewonnen. Noah will nun so lange weiter spielen, bis er seinen Verlust von* 1 *Euro wieder wettgemacht hat. Wieviele Runden müssen die beiden im Mittel noch spielen?*

(a) 2

(b) 4

(c) 8

(d) ∞

Beispiel 0.2. *Bei* 50 *aufeinanderfolgenden Würfen einer fairen Münze: mit welcher Wahrscheinlichkeit (W'keit) erscheint im Laufe der Würfe* 5 *mal hintereinander Zahl?*

Wir werden die W'keit später exakt berechnen. Hier die Frage: in welchem Intervall liegt die W'keit?

(a) $[0, \frac{1}{4}]$

(b) $(\frac{1}{4}, \frac{1}{2}]$

(c) $(\frac{1}{2}, \frac{3}{4}]$

(d) $(\frac{3}{4}, 1]$

Beispiel 0.3. *Im Pokal-Wettbewerb des DFB komme es zu einem Spiel zwischen einem Erstligisten und einem Drittligisten. Wir nehmen an, dass der Erstligist in den ersten 90 Spielminuten 20 Mal mal auf das Tor des Drittligisten schießt. Der Drittligist hingegen kommt nur zu 10 Torschüssen auf das gegnerische Tor. Des Weiteren nehmen wir an, dass der Erstligist im Mittel jeden zehnten Torschuss zu einem Tor verwandelt. Die Torschüsse des Drittligisten sind wegen der starken Defensive des Erstlisigsten nicht ganz so effizient. Nehmen wir an, dass nur jeder zwanzigste Torschuss des Drittligisten zu einem Tor führt. Die folgende Tabelle fasst unsere Annahmen zusammen:*

	Erstligist	*Drittligist*
Torschüsse	*20*	*10*
Trefferquote	*0.1*	*0.05*

Mit welcher W'keit führt der Erstligist nach 90 Minuten?

(a) 0.65

(b) 0.75

(c) 0.85

(d) 0.95

Die Beispiele zeigen: intuitive Schätzung oft weit weg von tatsächlicher W'keit.

Wie lassen sich die Antworten bestimmen? Benötigt (zumindest für Beispiel 0.2 und 0.3): wahrscheinlichkeitstheoretische Modelle und Methoden der Wahrscheinlichkeitstheorie.

1 Ergebnisräume und Ereignisse

Ein Ergebnisraum (ER) ist eine Menge, die alle möglichen Ausgänge eines Zufallsexperiments umfasst. Üblicherweise bezeichnet man ER mit dem Buchstaben Ω. Die Elemente von Ω werden auch Ergebnisse genannt.

Beispiele für Ergebnisräume:

a) Zufallsexperiment ist einmaliger Münzwurf:

$$\Omega = \{K, Z\}.$$

b) Zweifacher Münzwurf:

$$\Omega = \{K, Z\}^2 = \{(K, K), (K, Z), (Z, K), (Z, Z)\}.$$

c) 50-facher Münzwurf:

$$\Omega = \{K, Z\}^{50}.$$

d) n-facher Würfelwurf:

$$\Omega = \{1, 2, \ldots, 6\}^n.$$

e) Erzielte Tore in einem Fussballspiel:

$$\Omega = \mathbb{Z}_{\geq 0} := \{0, 1, 2, \ldots\}.$$

f) Mögliche Spielstände nach 90 Minuten in Beispiel 0.3 aus Kapitel 0:

$$\Omega = \{0, 1, \ldots, 20\} \times \{0, 1, \ldots, 10\}.$$

Ein *Ereignis* ist eine Teilmenge von Ω. Man sagt: ein Ereignis $A \subset \Omega$ tritt ein, falls das Ergebnis des Zufallsexperiments in A liegt.

Beispiele für Ereignisse:

a) Sei $\Omega = \{K, Z\}^2$ (zweifacher Münzwurf)

Ereignis in Worten	Ereignis als Teilmenge
1. Wurf ist Zahl	{(Z,K), (Z,Z)}
höchstens ein Wurf ist Zahl	{(K,K), (Z,K), (K,Z)}

b) Sei $\Omega = \mathbb{Z}_{\geq 0}$ (Tore im Fussballspiel)

Ereignis in Worten	Ereignis als Teilmenge
mind. 2 Tore	{2,3,4, ...}
höchstens 3 Tore	{0,1,2,3}
gerade Anzahl an Toren	{0,2,4,6, ...}

Seien A und B zwei Ereignisse von Ω. Neue Ereignisse:

$A \cup B$	A oder B tritt ein
$A \cap B$	A und B treten ein
$A \setminus B$	A tritt ein, B aber nicht
$A^c := \{\omega \in \Omega : \omega \notin A\}$	A tritt nicht ein

Bezeichnungen: Man bezeichnet A^c als das *Komplement* oder *Gegenereignis* von A. Ein Ereignis heißt *Elementarereignis*, falls es nur ein Ergebnis enthält. Wir bezeichnen mit $\mathcal{P}(\Omega) := \{A : A \subset \Omega\}$ die *Potenzmenge* von Ω.

2 Laplace-Experimente

Notation: die Mächtigkeit einer endlichen Menge A ist die Anzahl ihrer Elemente. Man schreibt kurz $|A|$.

Wir betrachten ein Zufallsexperiment mit endlichem Ergebnisraum Ω. Sei $n = |\Omega| \in \mathbb{N}$. Das Experiment heißt *Laplace-Experiment*, falls alle Ergebnisse mit derselben Wahrscheinlichkeit eintreten. Da es insgesamt n Ergebnisse gibt, tritt dann jedes Ergebnis mit W'keit $\frac{1}{n}$ ein. Weiterhin ist die W'keit eines Ereignisses $A \subset \Omega$ gegeben durch $P(A) := \frac{|A|}{|\Omega|}$.

Ausblick: die Abbildung

$$P : \mathcal{P}(\Omega) \to [0,1], A \mapsto \frac{|A|}{|\Omega|},$$

ist ein Beispiel für ein Wahrscheinlichkeitsmaß (siehe Kapitel 3 unten für eine allgemeinere Definition).

<u>Beispiele für Laplace-Experimente:</u>

a) Modell des einmaligen Wurfes einer fairen Münze: $\Omega = \{K, Z\}$ und

$$P(\{K\}) = P(\{Z\}) = \frac{1}{2}.$$

b) Modell des n-fachen Wurfes einer fairen Münze: $\Omega = \{K, Z\}^n$ und

$$P(\{\omega\}) = \frac{1}{2^n}.$$

c) Modell eines fairen Würfels: $\Omega = \{1, 2, \ldots, 6\}$ und

$$P(\{1\}) = P(\{2\}) = \cdots = P(\{6\}) = \frac{1}{6}.$$

Beispiel 2.1. *Wir werfen zwei Würfel. Wie groß ist die W'keit, dass die Augensumme* 8 *beträgt?*

Wir modellieren das Werfen beider Würfel als Laplace-Experiment mit Ergebnisraum $\Omega = \{1, \ldots, 6\}^2$. *Es bezeichne* A *das Ereignis, dass die Augensumme* 8 *ist. Dann gilt*

$$A = \{(2, 6), (3, 5), (4, 4), (5, 3), (6, 2)\}.$$

Also tritt A *ein mit einer W'keit von* $\frac{|A|}{|\Omega|} = \frac{5}{36}$.

Für die Modellierung von Laplace-Experimenten und zur Bestimmung der Mächtigkeiten von Ereignissen werden häufig Begriffe und Formeln der Kombinatorik verwendet. Deshalb:

2.1 Exkurs: Elemente der Kombinatorik

Wir führen einige Begriffe der Kombinatorik ein. Zur Illustration denken wir an eine Urne mit n gleichförmigen Kugeln, die mit 1 bis n durchnummeriert sind.

a) Ziehen wir k mal mit Zurücklegen und beachten die Reihenfolge, so erhalten wir eine <u>Variation mit Wiederholung</u> von k aus n Kugeln.

b) Ziehen wir k mal ohne Zurücklegen und beachten die Reihenfolge, so erhalten wir eine <u>Variation ohne Wiederholung</u> von k aus n Kugeln. Hierbei muss $k \leq n$ gelten.

Allgemein ist eine Variation (alt.: geordnete Stichprobe) eine Auswahl von k Objekten aus einer Menge von n Objekten, wobei die Reihenfolge eine Rolle spielt. Man unterscheidet zwischen Variationen mit und ohne Wiederholung.

Lemma 2.2. *a) Es gibt* n^k *Variationen mit Wiederholung von* k *aus* n *Objekten.*

b) Sei $k \in \{1, \ldots, n\}$. *Dann gibt es* $n(n-1)\ldots(n-k+1) = \frac{n!}{(n-k)!}$ *Variationen ohne Wiederholung von* k *aus* n *Objekten.*

Beweis. a) Es gibt eine Bijektion zwischen der Menge der Variationen mit Wdh von k aus n und der Menge $\{1, \ldots, n\}^k$. Die zweite Menge hat n^k Elemente.

b) Die Variationen ohne Wdh lassen sich identifizieren mit der Menge aller Tupel in $\{1, \ldots, n\}^k$, für die keine zwei Einträge übereinstimmen. Für den ersten Eintrag gibt es n mögliche Werte, für den zweiten $n-1$, usw und für den k-ten Eintrag gibt es $n-k+1$ mögliche Werte. □

Weitere Begriffe:

c) Ziehen wir k mal ohne Zurücklegen und ignorieren die Reihenfolge, so erhalten wir eine <u>Kombination ohne Wiederholung</u> von k aus n Kugeln.

d) Ziehen wir k mal mit Zurücklegen und ignorieren die Reihenfolge, so erhalten wir eine <u>Kombinationen mit Wiederholung</u> von k aus n Kugeln.

Allgemein ist eine Kombination (alt: ungeordnete Stichproben) eine Auswahl von k Objekten aus einer Menge von n Objekten, wobei die Reihenfolge *keine* Rolle spielt.

Lemma 2.3. *a) Sei $k \in \{1, \ldots, n\}$. Es gibt $\binom{n}{k} := \frac{n!}{(n-k)!k!}$ Kombinationen ohne Wiederholung von k aus n Objekten.*

b) Es gibt $\binom{n+k-1}{k} = \frac{(n+k-1)!}{(n-1)!k!}$ Kombinationen mit Wiederholung von k aus n Objekten.

Beweis. a) Aus einer Kombination ohne Wdh von k aus n Objekten lassen sich $k!$ verschiedene Variationen konstruieren. Mit anderen Worten: es gibt $k!$ mehr Variationen ohne Wdh als Kombinationen ohne Wdh. Also gibt es $\frac{n!}{(n-k)!k!} = \binom{n}{k}$ Kombinationen ohne Wdh.

b) Wir betrachten zunächst den Fall $n = 5$ und $k = 3$. Jede Kombination entspricht einer Folge der Länge 7 mit den Symbolen $|$ und $\star$:

(224) entspricht $|\star\star||\star|$

(125) entspricht $\star|\star|||\star$

Beachte: Es gibt $\binom{7}{3}$ Symbolfolgen der Länge 7 mit genau 3 Sternen.

Allgemein gilt: es gibt eine Bijektion zwischen den Kombinationen mit Wdh und der Menge der Symbolfolgen der Länge $n+k-1$ mit genau k Sternen. Da es $\binom{n+k-1}{k}$ solche Symbolfolgen gibt, folgt die Aussage. □

2.2 Modellierung von Laplace-Experimenten mit Variationen und Kombinationen

Wir illustrieren an Hand von Beispielen, wie man mit Hilfe von Variationen bzw Kombinationen Zufallsexperimente als Laplace-Experimente modellieren

kann.

Beispiel 2.4. *In einer Übung sitzen 23 Studierende. Mit welcher W'keit haben alle an unterschiedlichen Tagen Geburtstag? Der Einfachheit halber ignorieren wir Schaltjahre.*

Experiment: $\Omega =$ *Menge der Variationen mit Wiederholung, wobei* $n = 365$ *und* $k = 23$. *Die W'keit eines Ergebnisses ist* $P(\{\omega\}) = \frac{1}{|\Omega|} = \frac{1}{365^{23}}$.

Das Ereignis 'Alle an unterschiedlichen Tagen Geburtstag' ist dann

$$A := \text{ Menge der Variationen ohne Wiederholung von } 23 \text{ aus } \{1, \ldots, 365\}.$$

Für die gesuchte W'keit erhalten wir

$$P(A) = \frac{|A|}{|\Omega|} = \frac{365!}{(365-23)!\ 365^{23}} \approx 0,49.$$

Fazit: Es ist wahrscheinlicher, dass 2 Studierende am selben Tag Geburtstag haben als nicht!

Beispiel 2.5. *Man zieht 2 mal ohne Zurücklegen aus einer Urne mit 7 schwarzen und 5 weißen Kugeln. Mit welcher W'keit zieht man zweimal schwarz?*

Für die Beantwortung denke man sich die Kugeln durchnummeriert. Die ersten 7 seien schwarz, die letzten 5 weiß. Das Ziehen zweier Kugeln lässt sich auf auf folgende zwei Arten als Laplace-Experiment modellieren:

1. Modellierung: Sei

$$\Omega = \text{ Menge der Kombinationen ohne Wiederholung, wobei } n = 12 \text{ und } k = 2.$$

Das Ereignis 'Beide schwarz' ist

$$A = \{\{\omega_1, \omega_2\} : \omega_1, \omega_2 \in \{1, 2, \ldots, 7\} \text{ und } \omega_1 \neq \omega_2\}.$$

Beachte $|A| = \binom{7}{2}$. *Die gesuchte W'keit ist somit*

$$P(A) = \frac{|A|}{|\Omega|} = \frac{\binom{7}{2}}{\binom{12}{2}} = \frac{\frac{7*6}{2}}{\frac{12*11}{2}} = \frac{7}{22}.$$

2. Modellierung: Sei

$$\tilde{\Omega} = \text{ Menge der Variationen ohne Wiederholung, wobei } n = 12 \text{ und } k = 2.$$

In diesem Modell ist das Ereignis 'Beide schwarz' gegeben durch die Menge

$$A = \{(i, j) : i, j \in \{1, 2, \ldots, 7\} \text{ und } i \neq j\}.$$

A enthält $7 * 6$ Elemente. Also gilt

$$P(A) = \frac{|A|}{|\Omega|} = \frac{7 * 6}{12 * 11} = \frac{7}{22}.$$

Bemerkung: im nächsten Abschnitt werden wir noch einen dritten Lösungsweg kennenlernen.

Beispiel 2.6. *Mit welcher W'keit haben Sie 6 Richtige beim Lotto '6 aus 49'? Modell: Ω = Menge der Kombinationen ohne Wiederholung, wobei $n = 49$ und $k = 6$. P ist WM mit $P(\{\omega\}) = \frac{1}{|\Omega|}$. Beachte $|\Omega| = \binom{49}{6}$.*

Also ist die gesuchte W'keit $\frac{1}{\binom{49}{6}} \approx 7,15 * 10^{-8}$.

Zum Vergleich: Rel. Häufigkeit eines Verkehrstod in D: $\approx 3 * 10^{-5}$ pro Jahr.

2.3 Lange Sequenzen von Zahl-Würfen

Ziel: Methode, um Frage aus Beispiel 0.2 zu beantworten.

Dazu: Wie groß ist die W'keit, dass bei n Würfen einer fairen Münze höchstens x mal hintereinander Z (= Zahl) erscheint?

Hierzu sei $\Omega_n = \{K, Z\}^n$ und P_n das WM mit $P_n(\{\omega\}) = \frac{1}{|\Omega_n|} = \frac{1}{2^n}$.

$A_n(x)$ = 'Keine Z-Teilsequenz länger als x'.

$a_n(x) := |A_n(x)|$.

Beachte: falls $x \geq n$, dann ist $a_n(x) = 2^n$. Für später setzen wir $a_0(x) = 1$.

Für festes x lässt sich $a_n(x)$ rekursiv in n berechnen.

Beispiel: jede Folge in $A_n(2)$ startet mit K, ZK oder ZZK. Beachte: In $A_n(2)$ gibt es

- $a_{n-1}(2)$ Elemente, die mit K starten,
- $a_{n-2}(2)$ Elemente, die mit ZK starten,
- $a_{n-3}(2)$ Elemente, die mit ZZK starten.

Also gilt für alle $n \geq 3$:

$$a_n(2) = a_{n-1}(2) + a_{n-2}(2) + a_{n-3}(2).$$

Allgemein lässt sich zeigen:

$$a_n(x) = \sum_{j=0}^{x} a_{n-1-j}(x). \tag{2.1}$$

Für die W'keit von $A(x)$ gilt also

$$P_n(A_n(x)) = \frac{a_n(x)}{2^n}. \tag{2.2}$$

Die Formeln (2.1) und (2.2) lassen sich gut implementieren. Im Beispiel 0.2 ist die W'keit des Komplements von $A_{50}(4)$ gesucht. Numerische Berechnung zeigt:

$$P_{50}(A_{50}(4)^c) = \frac{|A_{50}^c|}{2^{50}} = \frac{2^{50} - |A_{50}|}{2^{50}} = 1 - \frac{a_{50}(4)}{2^{50}} \approx 0,55.$$

2.4 Ausblick

Nicht jedes Zufallsexperiment kann als Laplace-Experiment modelliert werden. Dies ist zum Beispiel der Fall, falls es abzählbar unendliche viele Ergebnisse gibt. Für die Modellierung von allgemeinen Zufallsexperimenten benötigen wir weitere Begriffe. Im nächsten Kapitel führen wir die allgemeine Definition von Wahrscheinlichkeitsmaßen ein.

3 Wahrscheinlichkeitsmaße

Manchmal sind überabzählbare ER gewünscht. Beispiele:

- $\mathbb{R}$ oder Intervall von reellen Zahlen
- Unendliche Kopf-Zahl-Folgen $\{K, Z\}^{\mathbb{N}}$.

Falls man bei der Modellierung ein überabzählbares Ω wählt, kann i.A. kein sinnvolles WM auf $\mathcal{P}(\Omega)$ definiert werden (siehe Satz 3.6 unten). Deshalb beschränkt man sich in solchen Fällen auf eine hinreichend reichhaltige Menge $\mathcal{A}$ von Ereignissen mit folgenden Eigenschaften:

(1) $\Omega \in \mathcal{A}$,

(2) $A \in \mathcal{A} \implies A^c \in \mathcal{A}$,

(3) $A_1, A_2, \ldots \in \mathcal{A} \implies \bigcup_{n=1}^{\infty} A_n \in \mathcal{A}$,

(4) $A_1, A_2, \ldots \in \mathcal{A} \implies \bigcap_{n=1}^{\infty} A_n \in \mathcal{A}$.

Eine Menge $\mathcal{A}$ von Teilmengen einer nichtleeren Menge Ω mit den Eigenschaften (1) - (4) heißt σ-Algebra auf Ω. In der W'theorie werden die Elemente einer σ-Algebra als Ereignisse bezeichnet.

Definition 3.1. Sei $\mathcal{A}$ eine σ-Algebra auf $\Omega \neq \emptyset$. Eine Abbildung $P : \mathcal{A} \to [0,1]$ heißt Wahrscheinlichkeitsmaß, falls gilt:

(W1) $P(\Omega) = 1$;

(W2) sind $A_1, A_2, \ldots$ disjunkte Ereignisse in $\mathcal{A}$ (dh $A_i \cap A_j = \emptyset$ für $i \neq j$), dann gilt

$$P\left(\bigcup_{n=1}^{\infty} A_n\right) = \sum_{n=1}^{\infty} P(A_n) \qquad (\sigma - \text{Additivität}).$$

Man sagt: $P(A)$ ist die Wahrscheinlichkeit des Ereignisses A.

Bemerkung. a) Die Eigenschaften (W1) und (W2) werden häufig als Kolmogorvsche Axiome bezeichnet. Aus diesen Axiomen folgen bereits viele weitere Eigenschaften. Man ist eventuell geneigt, noch weitere Eigenschaften in die Definition zu packen; dies braucht man aber nicht, da alle plausiblen Eigenschaften bereits aus (W1) und (W2) folgen (siehe Satz 3.2 unten).

b) Die Reihenfolge der Summation in $\sum_{n=1}^{\infty} P(A_n)$ spielt keine Rolle, da alle Summanden nicht-negativ sind.

Satz 3.2 (Eigenschaften von WM)**.** *Sei $\mathcal{A}$ eine σ-Algebra auf $\Omega \neq \emptyset$, und $P : \mathcal{A} \to [0,1]$ eine Abbildung mit den Eigenschaften (W1) und (W2). Dann gilt:*

(1) $P(\emptyset) = 0$,

(2) Sind A und B disjunkte Ereignisse in $\mathcal{A}$, dann gilt

$$P(A \cup B) = P(A) + P(B) \qquad (\textit{endliche Additivität}).$$

(3) Monotonie:

$$A \subset B \Longrightarrow P(A) \leq P(B)$$

(4) $P(A^c) = 1 - P(A)$,

(5) $P(A \setminus B) = P(A) - P(A \cap B)$,

(6) $P(A \cup B) = P(A) + P(B) - P(A \cap B)$.

(7) Sub-Additivität: Sind A und B beliebige Ereignisse, so gilt

$$P(A \cup B) \leq P(A) + P(B),$$

und für eine beliebige Folge von Ereignissen $A_1, A_2, \ldots$ gilt

$$P\left(\bigcup_{i=1}^{\infty} A_i\right) \leq \sum_{i=1}^{\infty} P(A_i).$$

Beweis. (1) Setze $A_n = \emptyset$ für alle $n \geq 1$. Dann folgt aus (W2)

$$P(\emptyset) = P(\bigcup_{n=1}^{\infty} A_n) = \sum_{n=1}^{\infty} P(A_n) = P(\emptyset) + P(\emptyset) + \cdots .$$

Da $P(\emptyset) \in [0,1]$, muss $P(\emptyset) = 0$ gelten.

(2) Hier setzen wir $A_1 = A$, $A_2 = B$ und $A_m = \emptyset$ für alle $m \geq 3$. Dann folgt aus (W2) und (1)

$$P(A \cup B) = P\left(\bigcup_{i=1}^{\infty} A_i\right) \overset{(W2)}{=} \sum_{i=1}^{\infty} P(A_i) \overset{(1)}{=} P(A) + P(B).$$

(3) Sei $A \subset B$. Dann ist B disjunkte Vereinigung von A und $B \setminus A$. Wegen Eig. (2) gilt somit

$$P(B) = P(A) + P(B \setminus A).$$

Da $P(B \setminus A) \geq 0$, folgt hieraus $P(B) \geq P(A)$.

(4) Beachte: Ω ist disjunkte Vereinigung von A und A^c. Also, wegen (2),

$$P(\Omega) = P(A) + P(A^c).$$

Da $P(\Omega) = 1$, folgt (4).

(5) Beachte: $A \setminus B = A \cap B^c$ und A ist disjunkte Vereinigung von $A \cap B$ und $A \cap B^c$. Also, wegen (2),

$$P(A) = P(A \cap B) + P(A \cap B^c) = P(A \cap B) + P(A \setminus B).$$

Hieraus folgt (5).

(6) $A \cup B$ ist disjunkte Vereinigung von A und $B \setminus A$. Also

$$\begin{aligned} P(A \cup B) &\overset{(2)}{=} P(A) + P(B \setminus A) \\ &\overset{(5)}{=} P(A) + P(B) - P(A \cap B). \end{aligned}$$

(7) Die Sub-Additivität zweier Ereignisse folgt aus (6), da $P(A \cap B) \geq 0$. Sei $A_1, A_2, \ldots$ ein Folge von Ereignissen. Wir definieren $B_1 = A_1$ und $B_n = A_n \setminus (A_1 \cup \ldots, \cup A_{n-1})$ für $n \geq 2$. Dann gilt

$$P\left(\bigcup_{i=1}^{\infty} A_i\right) = P\left(\bigcup_{i=1}^{\infty} B_i\right) \overset{(W2)}{=} \sum_{i=1}^{\infty} P(B_i) \overset{(3)}{\leq} \sum_{i=1}^{\infty} P(A_i).$$

□

Bezeichnung: ein Tripel $(\Omega, \mathcal{A}, P)$ bestehend aus ER, σ-Algebra und WM heißt *Wahrscheinlichkeitsraum* (WR).

Beispiel 3.3. *Sei Ω abzählbar und $\mathcal{A} = \mathcal{P}(\Omega)$. Jedes Ereignis $A \in \mathcal{A}$ ist abzählbare Vereinigung der Elementarereignisse $\{\omega\}$ mit $\omega \in A$. Also folgt aus (W2) bzw der endlichen Additivität:*

$$P(A) = \sum_{\omega \in A} P(\{\omega\}). \tag{3.1}$$

In diesem Fall ist also das Wahrscheinlichkeitsmaß eindeutig charakterisiert durch die Wahrscheinlichkeiten der Elementarereignisse.

Satz 3.4. *Sei $(\Omega, \mathcal{A}, P)$ ein WR und seien $A_1, \ldots, A_n$ Ereignisse in $\mathcal{A}$. Dann gilt*

$$\begin{aligned} P\left(\bigcup_{i=1}^{n} A_i\right) = &\sum_{i=1}^{n} P(A_i) - \sum_{1 \leq i < j \leq n}^{n} P(A_i \cap A_j) \\ &+ \sum_{1 \leq i < j < k \leq n}^{n} P(A_i \cap A_j \cap A_k) + \cdots + (-1)^{n+1} P(A_1 \cap \cdots \cap A_n). \end{aligned}$$

Beweis. Übung. □

Satz 3.5 (σ-Stetigkeit von P)**.** *Sei $(\Omega, \mathcal{A}, P)$ ein WR.*

a) Sei (A_n) eine absteigende Folge von Ereignissen (d.h. es gelte $A_1 \supset A_2 \supset A_3 \supset \cdots$). Dann gilt $\lim_n P(A_n) = P(\bigcap_{n \geq 1} A_n)$.

b) Sei (B_n) eine aufsteigende Folge von Ereignissen (d.h. es gelte $B_1 \subset B_2 \subset B_3 \subset \cdots$). Dann gilt $\lim_n P(B_n) = P(\bigcup_{n \geq 1} B_n)$.

Beweis. a) Sei $A_\infty := \bigcap_{n\geq 1} A_n$ und $C_n = A_n \backslash A_{n+1}$. Dann sind $A_\infty, C_1, C_2, \ldots$ disjunkt. Weiterhin gilt $A_n = A_\infty \cup C_n \cup C_{n+1} \cup \cdots$ für alle $n \geq 1$. Aus der σ-Additivität von P folgt somit

$$P(A_n) = P(A_\infty) + \sum_{m=n}^{\infty} P(C_m). \tag{3.2}$$

Da $\sum_{m=1}^{\infty} P(C_m) \leq 1$, folgt $\lim_{n\to\infty} \sum_{m=n}^{\infty} P(C_m) = 0$. Aus (3.2) folgt somit $\lim_{n\to\infty} P(A_n) = P(A_\infty)$.

b) Die Folge (B_n^c) ist absteigend und somit gilt wegen a)

$$\lim_n P(B_n^c) = P\left(\bigcap_{n\geq 1} B_n^c\right) = P\left(\left(\bigcup_{n\geq 1} B_n\right)^c\right).$$

Folglich,

$$\lim_n P(B_n) = \lim_n (1 - P(B_n^c)) = 1 - P\left(\left(\bigcup_{n\geq 1} B_n\right)^c\right) = P\left(\bigcup_{n\geq 1} B_n\right).$$

□

Zum Schluss dieses Kapitels versuchen wir ein Modell für das Gedankenexperiment aufzustellen, in dem eine Münze unendlich oft hintereinander geworfen wird. Dazu sei $\Omega = \{0,1\}^{\mathbb{N}}$ (oder äquivalent dazu $\Omega = \{K, Z\}^{\mathbb{N}}$). Für jedes $n \in \mathbb{N}$ sei T_n die Abbildung auf Ω, die den n-ten Wurf ändert:

$$T_n : \Omega \to \Omega, \quad \omega = (\omega_1, \omega_2, \ldots) \mapsto (\omega_1, \ldots, \omega_{n-1}, 1 - \omega_n, \omega_{n+1}, \ldots).$$

Ist die Münze fair, so muss für alle Ereignisse A gelten, dass $T_n(A)$ genauso wahrscheinlich ist wie A. Nun gilt aber Folgendes:

Satz 3.6. *Sei $\Omega = \{0,1\}^{\mathbb{N}}$. Dann gibt es keine Abbildung $P : \mathcal{P}(\Omega) \to [0,1]$ mit den Eigenschaften (W1), (W2) und*

$$P(T_n(A)) = P(A), \text{ für alle } A \subset \Omega. \tag{3.3}$$

Beweis. Wir führen folgende Äquivalenzrelation auf Ω ein: ω ist äquivalent zu ω', falls es ein $N \in \mathbb{N}$ gibt, sodass für alle $n \geq N$ gilt: $\omega_n = \omega'_n$.

Sei nun A eine Teilmenge von Ω, die von jeder Äquivalenzklasse genau ein Element enthält (hier verwenden wir das Auswahlaxiom!). Weiterhin sei $\mathcal{M}$ die Menge aller endlichen Teilmengen von $\mathbb{N}$. Beachte: $\mathcal{M}$ is abzählbar.

Für $M = \{n_1, \ldots, n_k\} \subset \mathbb{N}$ sei T_M die Komposition der Abbildungen $T_{n_1}, \ldots, T_{n_k}$. Für eine Abbildung $P : \mathcal{P}(\Omega) \to [0,1]$ mit (3.3) gilt

$$\begin{aligned} P(T_M(A)) &= P(T_{n_k} \circ \cdots \circ T_{n_1}(A)) = P(T_{n_{k-1}} \circ \cdots \circ T_{n_1}(A)) = \ldots \\ &= P(A). \end{aligned} \tag{3.4}$$

Weiterhin gilt für zwei Mengen $M, L \in \mathcal{M}$ mit $M \neq L$, dass $T_M(A)$ und $T_L(A)$ disjunkt sind. Begründung hierfür: Angenommen $\omega \in T_M(A) \cap T_L(A)$. Dann existieren $\omega', \omega'' \in A$ mit $\omega = T_M(\omega')$ und $\omega = T_M(\omega'')$. Insbesondere gilt $\omega \sim \omega'$ und $\omega \sim \omega''$. Aus der Transitivität folgt $\omega' \sim \omega''$. Da A aus jeder Äquivalenzklasse nur ein Element enthält, folgt also $\omega' = \omega''$. Dies ist aber ein Widerspruch zu $\omega' = T_M(\omega) \neq T_L(\omega) = \omega''$.

Als nächstes beachte: $\bigcup_{M \in \mathcal{M}} T_M(A) = \Omega$.

Ist nun $P : \mathcal{P}(\Omega) \to [0,1]$ eine Abbildung mit den Eigenschaften (W1), (W2) und (3.4), so folgt

$$1 \overset{(W1)}{=} P(\Omega) \overset{(W2)}{=} \sum_{M \in \mathcal{M}} P(T_M(A)) \overset{(3.4)}{=} \sum_{M \in \mathcal{M}} P(A).$$

Dies führt zu einem Widerspruch, da die Summe rechts nur den Wert 0 oder unendlich annehmen kann. □

Satz 3.6 zeigt, dass die Potenzmenge von $\{0,1\}^{\mathbb{N}}$ keine geeignete σ-Algebra ist, um den unendlichen Münzwurf zu modellieren. Was ist dann eine geeignete σ-Algebra? Man kann zeigen, dass die kleinste σ-Algebra geeignet ist, die alle Ereignisse enthält, die man mit Hilfe endlich vieler Münzwürfe beschreiben kann. Auf dieser σ-Algebra lässt sich ein WM definieren mit der Eigenschaft (3.3) (siehe kommendes Semester).

4 Bedingte Wahrscheinlichkeiten

Sei $(\Omega, \mathcal{A}, P)$ ein WR.

Definition 4.1. Seien B, C Ereignisse in $\mathcal{A}$ und $P(C) > 0$. Die bedingte W'keit von B bez. C ist definiert durch

$$P(B|C) = \frac{P(B \cap C)}{P(C)}.$$

Beispiel 4.2. *In einer Urne seien 10 gleichförmige, durchnummerierte Kugeln. Sie ziehen blind eine Kugel. Jmd sagt Ihnen, dass die Nr. der gezogenen Kugel mind. 5 ist. Mit welcher W'keit haben Sie die 10. Kugel gezogen?*

Modell für das Ziehen einer Kugel: $\Omega = \{1, 2, \ldots, 10\}$, P *WM mit* $P(A) = \frac{|A|}{|\Omega|}$, $A \subset \Omega$. *In diesem Bsp ist* $B = \{10\}$ *und* $C = \{5, 6, \ldots, 10\}$. *Gesucht ist die bedingte W'keit* $P(B|C)$. *Es gilt*

$$P(B|C) = \frac{P(B \cap C)}{P(C)} = \frac{|B \cap C|}{|C|} = \frac{1}{6}.$$

Beispiel 4.3. *Herr Maier hat 2 Kinder. Das ältere Kind ist ein Mädchen. Wie groß ist die W'keit, dass beide Kinder Mädchen sind? Wir nehmen an: Mädchen und Jungen sind gleich häufig.*

Modell: $\Omega = \{(M, M), (M, J), (J, M), (J, J)\}$, *wobei die 1. Komponente das ältere Kind ist.* P *ist das WM mit* $P(A) = \frac{|A|}{|\Omega|}$, $A \in \mathcal{P}(\Omega)$.

Setze $C = \{(M, M), (M, J)\}$ *und* $B = \{(M, M)\}$. *Die gesuchte W'keit ist*

$$P(B|C) = \frac{P(B \cap C)}{P(C)} = \frac{|B \cap C|}{|C|} = \frac{1}{2}.$$

Beispiel 4.4. *Frau Schmidt hat 2 Kinder. Mind. ein Kind ist ein Mädchen. Wie groß ist die W'keit, dass beide Kinder Mädchen sind? Wir nehmen wieder an: Mädchen und Jungen sind gleich häufig.*

Wähle dasselbe Modell wie in Beispiel 4.3.

Hier setze $C = \{(M, M), (M, J), (J, M)\}$ *und* $B = \{(M, M)\}$. *Die gesuchte W'keit ist*

$$P(B|C) = \frac{P(B \cap C)}{P(C)} = \frac{|B \cap C|}{|C|} = \frac{1}{3}.$$

Beispiel 4.5 (siehe Beispiel 2.5)**.** *Betrachte wieder Beispiel 2.5. Es bezeichne* B *das Ereignis, dass die erste gezogene Kugel schwarz ist.* C *sei das Ereignis, dass die zweite Kugel schwarz ist. Dann muss gelten*

$$P(B) = \frac{7}{12} \quad \textit{und} \quad P(C|B) = \frac{6}{11}.$$

Folglich ist die W'keit, dass man zweimal schwarz zieht gegeben durch

$$P(B \cap C) = P(C|B)P(B) = \frac{7}{12}\frac{6}{11} = \frac{7}{22}.$$

Satz 4.6 (Satz von der totalen W'keit)**.** *Seien $A_1, \ldots, A_n$ disjunkte Ereignisse mit $\bigcup_{i=1}^n A_i = \Omega$ und $P(A_i) > 0$, $1 \leq i \leq n$. Dann gilt für alle Ereignisse B*

$$P(B) = \sum_{i=1}^n P(B|A_i)P(A_i). \tag{4.1}$$

Beweis. Aus der endlichen Additivität von P folgt

$$P(B) = P\left(\bigcup_{i=1}^n (B \cap A_i)\right) = \sum_{i=1}^n P(B \cap A_i).$$

Für jeden Summanden gilt $P(B \cap A_i) = P(B|A_i)P(A_i)$. Also folgt (4.1). □

Beispiel 4.7. *Gegeben seien 2 Urnen mit Kugeln:*
Urne 1: 7 schwarze, 2 weiße Kugeln
Urne 2: 6 schwarze, 5 weiße Kugeln.

Wir werfen eine faire Münze. Bei K ziehen wir einmal aus Urne 1, bei Z einmal aus Urne 2. Mit welcher W'keit zieht man eine weiße Kugel?

Modell: Sei $A_1 = \{(K, u) : u \in \{1, 2, \ldots, 9\}\}$, $A_2 = \{(Z, u) : u \in \{1, 2, \ldots, 11\}\}$ und

$$\Omega = A_1 \cup A_2.$$

B bezeichne das Ereignis 'Weiße Kugel' und P sei das WM mit $P(A_1) = P(A_2) = \frac{1}{2}$, $P(B|A_1) = \frac{2}{9}$ und $P(B|A_2) = \frac{5}{11}$. Dann gilt nach Satz 4.6

$$P(B) = P(A_1)P(B|A_1) + P(A_2)P(B|A_2) = \frac{1}{2} \cdot \frac{2}{9} + \frac{1}{2} \cdot \frac{5}{11} = \frac{1}{9} + \frac{5}{22} = \frac{67}{198}.$$

Bemerkung. Satz 4.6 zeigt, wie man aus bedingten W'keiten Unbedingte bestimmen kann. Veranschaulichung von Beispiel 4.7 mit Baum:

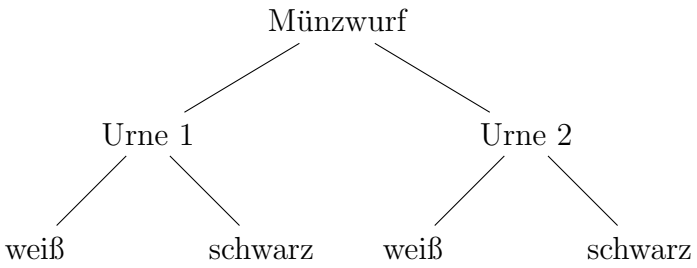

Satz 4.8 (Formel von Bayes)**.** *Seien $A_1, \ldots, A_n$ disjunkte Ereignisse mit $\bigcup_{i=1}^n A_i = \Omega$ und $P(A_i) > 0$, $1 \leq i \leq n$. Sei B ein Ereignis mit $P(B) > 0$. Dann gilt*

$$P(A_n|B) = \frac{P(B|A_n)P(A_n)}{\sum_{i=1}^n P(B|A_i)P(A_i)}. \tag{4.2}$$

Beweis. Nach Satz 4.6 ist der Nenner der RS von (4.2) gleich $P(B)$. Der Zähler ist gleich $P(A_n \cap B)$. Also: RS von (4.2) $= \frac{P(A_n \cap B)}{P(B)} = P(A_n|B)$. $\square$

Fortsetzung von Beispiel 4.7. Mit welcher W'keit zeigt die Münze K, falls man eine weiße Kugel gezogen hat?

Modell wie in Bsp. 4.7 oben. Nach Satz 4.8 gilt

$$\begin{aligned} P(A_1|B) &= \frac{P(B|A_1)P(A_1)}{P(B|A_1)P(A_1) + P(B|A_2)P(A_2)} \\ &= \frac{\frac{2}{9} \cdot \frac{1}{2}}{\frac{2}{9} \cdot \frac{1}{2} + \frac{5}{11} \cdot \frac{1}{2}} \\ &= \frac{\frac{2}{9}}{\frac{2}{9} + \frac{5}{11}} \\ &= \frac{22}{67}. \end{aligned}$$

Die Formel von Bayes ist wichtig zum Beispiel in der Medizinstatistik.

Beispiel 4.9. $0,5$ *% der Bevölkerung habe eine Krankheit x. Für einen medizinischen Test auf x gelte: bei* 95 *% der Erkrankten ist der Test positiv; bei* 1*% der Nicht-Erkrankten ist der Test fälschlicherweise positiv. Mit welcher W'keit ist eine positiv getestete Person tatsächlich an x erkrankt?*

Ereignisse:

$$\begin{aligned} K &= \text{'getestete Person ist erkrankt'} \\ T_+ &= \text{'Test positiv'} \end{aligned}$$

Dann gilt: $P(K) = 0,005$, $P(K^c) = 0,995$, $P(T_+|K) = 0,95$, $P(T_+|K^c) = 0,01$.

Mit der Bayes-Formel (4.2) *folgt*

$$\begin{aligned} P(K|T_+) &= \frac{P(T_+|K)P(K)}{P(T_+|K)P(K) + P(T_+|K^c)P(K^c)} \\ &= \frac{0,95 \cdot 0,005}{0,95 \cdot 0,005 + 0,01 \cdot 0,995} \approx 0,323. \end{aligned}$$

5 Unabhängige Ereignisse

Sei $(\Omega, \mathcal{A}, P)$ ein WR.

Definition 5.1. Zwei Ereignisse A und B heißen (stochastisch) unabhängig, falls

$$P(A \cap B) = P(A)P(B).$$

Beispiel 5.2. *Modell für den 2-fachen Wurf eines fairen Würfels:* $\Omega = \{1, \ldots, 6\}^2$, $P(\{\omega\}) = \frac{1}{36}$.

$$\begin{aligned} A &= \text{'1. Wurf ist 4'} = \{(4,1),(4,2),\ldots,(4,6)\}, \\ B &= \text{'Augensumme ist 6'} = \{(1,5),(2,4),(3,3),(4,2),(5,1)\}. \end{aligned}$$

Es gilt

$$P(A \cap B) = P(\{(4,2)\}) = \frac{1}{36} \neq \frac{1}{6} \cdot \frac{5}{36} = P(A)P(B).$$

Also sind A und B nicht unabhängig.

Lemma 5.3. *Seien A, B Ereignisse und $P(B) > 0$. Dann gilt:*

$$A, B \text{ sind unabhängig} \iff P(A|B) = P(A).$$

Beweis. $\underline{\Longrightarrow:}$ $P(A|B) = \frac{P(A \cap B)}{P(B)} \overset{\text{unabh.}}{=} \frac{P(A)P(B)}{P(B)} = P(A)$.
$\underline{\Longleftarrow:}$ $P(A \cap B) = P(A|B)P(B) = P(A)P(B)$. □

Definition 5.4. Eine Familie von Ereignissen $(A_i)_{i \in I}$ heißt (stochastisch) unabhängig, falls für jede endliche Teilmenge $\{i_1, \ldots, i_k\} \subset I$ gilt:

$$P(A_{i_1} \cap \cdots \cap A_{i_k}) = P(A_{i_1}) \cdots P(A_{i_k}).$$

Beispiel 5.5 (Paarweise Unabhängigkeit $\not\Longrightarrow$ Unabhängigkeit)**.** *Wir ziehen ein Mal aus einer Urne mit 4 nummerierten Kugeln. Modell:* $\Omega = \{1,2,3,4\}$, $P(\{\omega\}) = \frac{1}{4}$.

Betrachte die Ereignisse

$$\begin{aligned} A &= \{1,2\}, \\ B &= \{1,3\}, \\ C &= \{1,4\}. \end{aligned}$$

Es gilt

$$P(A \cap B) = P(A \cap C) = P(B \cap C) = P(\{1\}) = \frac{1}{4},$$

und

$$P(A)P(B) = P(A)P(C) = P(B)P(C) = \frac{1}{2} \cdot \frac{1}{2} = \frac{1}{4}.$$

Also sind A, B, C paarweise unabhängig. Allerdings:

$$P(A \cap B \cap C) = P(\{1\}) = \frac{1}{4} \neq \frac{1}{8} = P(A)P(B)P(C).$$

Also sind A, B, C nicht unabhängig.

Satz 5.6. *Sei $A_1, \ldots, A_n$ eine unabhängige Familie von Ereignissen. Für alle $i \in \{1, \ldots, n\}$ sei B_i gleich A_i oder A_i^c. Dann ist auch $B_1, \ldots, B_n$ eine unabhängige Familie.*

Beweis für $n = 2$. Zunächst zeigen wir, dass A_1 und A_2^c unabhängig sind:

$$\begin{aligned} P(A_1 \cap A_2^c) &= P(A_1) - P(A_1 \cap A_2) && \text{(Eig. (5), Satz 3.2)} \\ &= P(A_1) - P(A_1)P(A_2) && \text{(Unabhängigkeit)} \\ &= P(A_1)(1 - P(A_2)) \\ &= P(A_1)P(A_2^c). \end{aligned}$$

Analog zeigt man $P(A_1^c \cap A_2) = P(A_1^c)P(A_2)$. Schließlich:

$$\begin{aligned} P(A_1^c \cap A_2^c) &= P(A_2^c) - P(A_2^c \cap A_1) && \text{(Eig. (5), Lemma 3.2)} \\ &= P(A_2^c) - P(A_2^c)P(A_1) && (A_1 \text{ und } A_2^c \text{ unabhängig}) \\ &= P(A_2^c)(1 - P(A_1)) \\ &= P(A_2^c 1)P(A_1^c). \end{aligned}$$

□

6 Zufallsvariablen und Verteilungen

6.1 Grundlegende Definitionen

Sei $(\Omega, \mathcal{A}, P)$ ein WR. Bei der mathematischen Beschreibung von Ereignissen sind oft Abbildungen auf dem ER hilfreich.

Beispiel 6.1. *Sei A das Ereignis 'Augensumme beim 2-fachen Würfeln ist 7'. Sei $\Omega = \{1, 2, \ldots, 6\}^2$ und $X : \Omega \to \mathbb{R}$, $(\omega_1, \omega_2) \mapsto \omega_1 + \omega_2$. Dann gilt*

$$A = \{\omega \in \Omega : X(\omega) = 7\}.$$

Kurzschreibweise: $\{X = 7\}$.

Beispiel 6.2. *In einem Zufallsexperiment werde eine Münze sehr oft hintereinander geworfen. Sei B_k das Ereignis 'Z erscheint zum ersten Mal beim k-ten Wurf'. Sei $\Omega = \{K, Z\}^{\mathbb{N}}$ und*

$$N(\omega) = \begin{cases} n, & \text{falls } \omega_1 = \cdots = \omega_{n-1} = K \text{ und } \omega_n = Z, \\ \infty, & \text{falls } \omega_1 = \omega_2 = \cdots = K. \end{cases}$$

Dann gilt

$$B_k = \{\omega \in \Omega : N(\omega) = k\} =: \{N = k\}.$$

Im Folgenden sei $X : \Omega \to [-\infty, \infty]$ ein Abbildung. Wir wollen Ereignissen, die mit X beschrieben werden, Wahrscheinlichkeiten zuordnen können. Damit dies möglich ist, muss X eine sogenannte Zufallsvariable sein:

Informelle Definition von Zufallsvariablen:

X heißt Zufallsvariable (ZV), falls alle Ereignisse, die mit X beschrieben werden können, in $\mathcal{A}$ liegen.

Mathematische Definition von Zufallsvariablen:

X heißt Zufallsvariable, falls für alle $y \in \mathbb{R}$ gilt:

$$\{X \leq y\} := \{\omega \in \Omega : X(\omega) \leq y\} \in \mathcal{A}. \tag{6.1}$$

Die Eigenschaft (6.1) besagt, dass unter X die Urbilder von allen Mengen der Form $[-\infty, y]$ in der σ-Algebra $\mathcal{A}$ liegen. Man kann zeigen: (6.1) impliziert, dass auch die Urbilder *aller* reellen Intervalle (abgeschlossen, halboffen, offen) in $\mathcal{A}$ liegen. Man kann sogar noch mehr zeigen: sei dazu $\mathcal{B}$ die kleinste σ-Algebra auf $[-\infty, \infty]$, die alle Teil-Intervalle von $[-\infty, \infty]$ enthält. Dann gilt:

Lemma 6.3. *Sei X eine Zufallsvariable. Dann liegt für alle $B \in \mathcal{B}$ das Urbild $\{X \in B\} := \{\omega \in \Omega : X(\omega) \in B\}$ in $\mathcal{A}$.*

Beweis. Maßtheorie, kommendes Semester. □

Informelle Definition von Verteilungen:

Die Verteilung einer Zufallsvariablen X beschreibt, welche Werte X mit welcher W'keit annimmt.

Mathematische Definition von Verteilungen:

Sei X eine Zufallsvariable. Die Verteilung von X ist das Wahrscheinlichkeitsmaß

$$Q : \mathcal{B} \to [0,1], B \mapsto P(X \in B).$$

6.2 Wichtige diskrete Verteilungen

Sei $(\Omega, \mathcal{A}, P)$ ein WR.

(a) Bernoulli-Verteilung

Eine Zufallsvariable $X : \Omega \to \mathbb{R}$ heißt Bernoulli-verteilt mit Parameter $p \in [0,1]$, falls

$$P(X = 1) = p \qquad \text{und} \qquad P(X = 0) = 1 - p.$$

Interpretation:
$\{X = 1\}$ 'Erfolg'
$\{X = 0\}$ 'Misserfolg'

(b) Binomial-Verteilung

Herleitung: Sie versuchen n mal einen Basketball in einen Korb zu werfen. Jedes Mal treffen sie mit W'keit $p \in (0,1)$. Mit welcher W'keit treffen Sie genau k mal?
Sei A_i = 'i-ter Wurf erfolgreich'. Wir nehmen an, dass $A_1, \ldots, A_n$ unabhängig sind.

Beachte: die W'keit bei den ersten k Würfen zu treffen, und danach nicht mehr, ist gegeben durch

$$\begin{aligned} &P(A_1 \cap \cdots \cap A_k \cap A_{k+1}^c \cap \cdots \cap A_n^c) \\ =&P(A_1) \cdots P(A_k) P(A_{k+1}^c) \cdots P(A_n^c) \qquad \text{(Satz 5.6)} \\ =&p^k (1-p)^{n-k}. \end{aligned}$$

Es gibt $\binom{n}{k}$ Möglichkeiten k Würfe aus n zu wählen. Also trifft man genau k mal mit W'keit $\binom{n}{k} p^k (1-p)^{n-k}$.

Definition 6.4. Eine Zufallsvariable $X : \Omega \to \mathbb{R}$ heißt binomialverteilt mit den Parametern n und p (kurz: $\mathcal{B}(n,p)$-verteilt), falls für alle $k \in \{0, 1, \ldots, n\}$ gilt:

$$P(X = k) = \binom{n}{k} p^k (1-p)^{n-k}.$$

Beispiel 6.5. *In einem Fussballspiel schießt CZ Jena* 20 *Mal auf das gegnerische Tor. Jeder Schuss landet im Tor mit W'keit* $\frac{1}{10}$. *Die Erfolge bei den Schüssen seien unabhängig. Mit welcher W'keit schießt CZ Jena höchstens* 1 *Tor?*

Wir modellieren die Anzahl der Tore als $\mathcal{B}(20, \frac{1}{10})$*-verteilte Zufallsvariable* X. *Dann gilt, mit* $p = 1/10$,

$$P(X = 0) = \binom{20}{0} p^0 (1-p)^{20} = (0.9)^{20} \approx 0,12,$$

und

$$P(X = 1) = \binom{20}{1} p^1 (1-p)^{19} = 20 * 0.1 * (0.9)^{19} \approx 0.27.$$

Also schießt CZ Jena höchstens 1 *Tor mit W'keit* ≈ 0.39.

(c) Geometrische Verteilung

Herleitung: Sie werfen solange einen Basketball Richtung Korb bis der Ball im Korb landet. Die Trefferw'keit für jeden einzelnen Wurf sei wieder $p \in (0,1)$. Mit welcher W'keit werden k Würfe benötigt bis der Ball im Korb landet?

Es bezeichne wieder A_i = 'i-ter Wurf erfolgreich', und wir nehmen an, dass für alle $n \in \mathbb{N}$ die Familie $A_1, \ldots, A_n$ unabhängig ist.

Die W'keit, dass der k-te Versuch der erste erfolgreiche Wurf ist, ist gegeben durch

$$\begin{aligned} & P(A_1^c \cap \cdots \cap A_{k-1}^c \cap A_k) \\ =& P(A_1^c) \cdots P(A_{k-1}^c) P(A_k) \qquad \text{(Satz 5.6)} \\ =& (1-p)^{k-1} p. \end{aligned}$$

Beachte: $\sum_{k=1}^{\infty} (1-p)^{k-1} p = p \sum_{k=0}^{\infty} (1-p)^k = p \frac{1}{1-(1-p)} = 1$.

Definition 6.6. Eine Zufallsvariable $X : \Omega \to \mathbb{R}$ heißt geometrisch-verteilt mit (Erfolgs-)Parameter p, falls für alle $k \in \mathbb{N}$ gilt:

$$P(X = k) = (1-p)^{k-1} p.$$

(d) Poisson-Verteilung

Definition 6.7. Eine Zufallsvariable $X : \Omega \to \mathbb{R}$ heißt Poisson-verteilt mit Parameter $\lambda \in (0, \infty)$ (kurz: Poi(λ)-verteilt), falls für alle $k \in \mathbb{Z}_{\geq 0}$ gilt:

$$P(X = k) = e^{-\lambda} \frac{\lambda^k}{k!}.$$

Beachte: $\sum_{k=0}^{\infty} e^{-\lambda} \frac{\lambda^k}{k!} = e^{-\lambda} \sum_{k=0}^{\infty} \frac{\lambda^k}{k!} = e^{-\lambda} e^{\lambda} = 1$.

Die Binomialverteilung $\mathcal{B}(n, p)$ lässt sich gut approximieren mit der Poissonverteilung, falls n groß ist und p klein. Um dies zu zeigen, setzen wir $\mathcal{B}(n, p; k) := \binom{n}{k} p^k (1-p)^{n-k}$.

Satz 6.8. *Sei $\lambda \in (0, \infty)$ und $p(n) = \frac{\lambda}{n}$ für alle $n \in \mathbb{N}$. Dann gilt für alle $k \in \mathbb{Z}_{\geq 0}$*

$$\lim_{n \to \infty} \mathcal{B}(n, p(n); k) = e^{-\lambda} \frac{\lambda^k}{k!}. \tag{6.2}$$

Beweis.

$$\begin{aligned}
\mathcal{B}(n, p(n); k) &= \binom{n}{k} p(n)^k (1 - p(n))^{n-k} \\
&= \frac{n(n-1)\cdots(n-k+1)}{k!} \left(\frac{\lambda}{n}\right)^k \left(1 - \frac{\lambda}{n}\right)^{n-k} \\
&= \frac{n}{n} \cdots \frac{n-k+1}{n} \, \frac{\lambda^k}{k!} \left(\frac{1}{1 - \frac{\lambda}{n}}\right)^k \left(1 - \frac{\lambda}{n}\right)^n. \qquad (6.3)
\end{aligned}$$

Beachte: $\lim_n \frac{n}{n} \cdots \frac{n-k+1}{n} = 1$ und $\lim_n \left(\frac{1}{1-\frac{\lambda}{n}}\right)^k = 1$. Weiterhin folgt aus Lemma 6.9 unten

$$\lim_n \left(1 - \frac{\lambda}{n}\right)^n = e^{-\lambda}.$$

Somit folgt aus (6.3) die Aussage (6.2). □

Lemma 6.9. *Für alle $x \in \mathbb{R}$ gilt $\lim_{n \to \infty} (1 + x/n)^n = e^x$.*

Proof. Mit der Regel von de L'Hospital folgt

$$\begin{aligned}
\lim_{n \to \infty} \ln\left((1 + x/n)^n\right) &= \lim_{n \to \infty} n \ln(1 + x/n) \\
&= \lim_{n \to \infty} \frac{\ln(1 + x/n)}{\frac{1}{n}} \\
&= \lim_{n \to \infty} \frac{\frac{-x/n^2}{1+x/n}}{-\frac{1}{n^2}} \qquad \text{(de L'Hopital)} \\
&= x.
\end{aligned}$$

Da die Exponentialfunktion stetig ist, folgt die Behauptung. $\square$

Fortsetzung von Beispiel 6.5. Erinnerung: Anzahl der Tore ist $\mathcal{B}(20, \frac{1}{10})$-verteilt. Wie gut ist die Approximation von $\mathcal{B}(20, \frac{1}{10})$ mit Poi(2)? (Beachte: λ muss gleich 2 gewählt werden, damit $p = \frac{\lambda}{n}$ gilt.)

Sei N Poi(2)-verteilt. Dann gilt

$$P(N = 0) = e^{-2}\frac{2^0}{0!} = e^{-2} \approx 0.135,$$
$$P(N = 1) = e^{-2}\frac{2^1}{1!} = 2e^{-2} \approx 0.27.$$

Bei den Verteilungen (a) - (d) sitzt die gesamte Masse des WM auf abzählbar vielen Punkten (daher der Name 'diskrete Verteilungen'). Die Aufzählung der Wahrscheinlichkeitsgewichte an diesen Punkten nennt man Zähldichte. Beispiele:

- Die Zähldichte der Binomialverteilung $\mathcal{B}(n, p)$ ist

$$p_k = \binom{n}{k} p^k (1-p)^{n-k}, \quad k \in \{0, \ldots, n\}.$$

- Die Zähldichte der geometrischen Verteilung ist

$$q_k = (1-p)^{k-1} p, \quad k \in \{1, 2, \ldots\}.$$

Im nächsten Abschnitt berachten wir Verteilungen, die sich nicht mit Zähldichten charakterisieren lassen, sondern durch integrierbare Funktionen.

6.3 Wichtige absolutstetige Verteilungen

Sei $(\Omega, \mathcal{A}, P)$ ein WR.

Definition 6.10. Eine Zufallsvariable $X : \Omega \to \mathbb{R}$ hat eine absolutstetige Verteilung, falls eine uneigentlich Riemann-integrierbare Funktion $f : \mathbb{R} \to [0, \infty)$ existiert mit

$$P(X \leq y) = \int_{-\infty}^{y} f(x)dx, \qquad y \in \mathbb{R}. \tag{6.4}$$

Die Funktion f heißt dann *Dichte* von X.

Aus der Eigenschaft (6.4) folgt:

Lemma 6.11. *Sei X eine Zufallsvariable mit Dichte f. Dann gilt für alle $y \in \mathbb{R}$*

$$P(X = y) = 0 \tag{6.5}$$

und für alle $a, b \in \mathbb{R}$ mit $a < b$

$$P(X \in [a,b]) = P(X \in [a,b)) = P(X \in (a,b]) = P(X \in (a,b)) = \int_a^b f(x)dx. \tag{6.6}$$

Beweis. Sei $a, b \in \mathbb{R}$ mit $a < b$. Wir zeigen zunächst $P(X \in (a,b]) = \int_a^b f(x)dx$. Dazu beachte, dass $\{X \in (a,b]\} = \{X \leq b\} \setminus \{X \leq a\}$. Wegen Eig. (5) aus Satz 3.2 und (6.4) gilt folglich

$$\begin{aligned} P(X \in (a,b]) = P(X \leq b) - P(X \leq a) &= \int_{-\infty}^b f(x)dx - \int_{-\infty}^a f(x)dx \\ &= \int_a^b f(x)dx. \end{aligned} \tag{6.7}$$

Wir zeigen nun (6.5). Für $y \in \mathbb{R}$ gilt $\{X = y\} = \bigcap_{n=1}^\infty \{X \in (y - \frac{1}{n}, y]\}$. Aus der σ-Stetigkeit von P (siehe Satz 3.5) folgt

$$P(X = y) = \lim_n P(X \in (y - \frac{1}{n}, y]) = \lim_n \int_{y-1/n}^y f(x)dx = 0.$$

Aus (6.5) folgt $P(X \in [a,b]) = P(X \in [a,b)) = P(X \in (a,b]) = P(X \in (a,b))$ und mit (6.7) somit (6.6). □

(e) Gleichverteilung auf einem beschränkten Intervall

Definition 6.12. Seien $a, b \in \mathbb{R}$ mit $a < b$. Eine Zufallsvariable $X : \Omega \to \mathbb{R}$ heißt gleichverteilt auf $[a,b]$ (kurz: $\mathcal{U}[a,b]$-verteilt), falls X die Dichte

$$f(x) = \begin{cases} \frac{1}{b-a}, & x \in [a,b], \\ 0, & x \notin [a,b], \end{cases}$$

hat.

Beispiel 6.13. *X sei $\mathcal{U}[0,10]$-verteilt. Mit welcher W'keit tritt das Ereignis $\{X \in [1,6]\}$ ein?*

Beachte: die Dichte von X nimmt zwischen 0 und 10 den Wert $1/10$ an, und sonst den Wert 0. Also gilt

$$P(X \in [1,6]) = \int_1^6 \frac{1}{10} dx = \frac{1}{10}(6-1) = \frac{1}{2}.$$

Bemerkung: Da einzelne Punkte die W'keit 0 haben, gibt es keinen Unterschied zwischen $\mathcal{U}[a,b]$ und $\mathcal{U}(a,b)$.

(f) Exponentialverteilung

Definition 6.14. Eine Zufallsvariable $X : \Omega \to \mathbb{R}$ heißt exponentialverteilt zum Parameter $\alpha \in (0, \infty)$ (kurz: Exp(α)-verteilt), falls X die Dichte

$$f(x) = \begin{cases} \alpha e^{-\alpha x}, & x \geq 0, \\ 0, & x < 0, \end{cases}$$

hat.

Beachte: $\int_{-\infty}^{\infty} f(x)dx = \int_0^{\infty} \alpha e^{-\alpha x} dx = \left(-e^{-\alpha x}\big|_0^{\infty}\right) = 1.$

(g) Normalverteilung

Definition 6.15. Eine Zufallsvariable $X : \Omega \to \mathbb{R}$ heißt normalverteilt mit Mittelwert $\mu \in \mathbb{R}$ und Varianz $v \in (0, \infty)$ (kurz: $\mathcal{N}(\mu, v)$-verteilt), falls X die Dichte

$$\varphi_{\mu,v}(x) := \frac{1}{\sqrt{2\pi v}} e^{-\frac{(x-\mu)^2}{2v}}, x \in \mathbb{R},$$

hat. Falls $\mu = 0$ und $v = 1$, dann heißt X standard-normalverteilt.

Wie zeigt man $\int_{-\infty}^{\infty} \varphi_{\mu,v}(x)dx = 1$?

6.4 Unabhängige Zufallsvariablen

Erinnerung: $\mathcal{B}$ ist die kleinste σ-Algebra auf $[-\infty, \infty]$, die alle Intervalle in $[-\infty, \infty]$ enthält.

Definition 6.16. Eine endliche Familie von Zufallsvariablen $X_1, \ldots, X_n$ heißt (stochastisch) unabhängig, falls für alle $A_1, \ldots, A_n \in \mathcal{B}$ gilt:

$$P\left(\bigcap_{i=1}^{n} \{X_i \in A_i\}\right) = \prod_{i=1}^{n} P(X_i \in A_i).$$

Eine Folge von Zufallsvariablen $X_1, X_2, \ldots$ heißt unabhängig, falls jede endliche Teilfamilie unabhängig ist.

Bei der Modellierung von Zufallsexperimenten nimmt man häufig Unabhängigkeit von Zufallsvariablen an, wie zB hier:

Beispiel 6.17. *Ziel: Herleitung der richtigen Antwort auf die Frage aus Beispiel 0.3.*

Wir präzisieren zunächst das Modell: Wir modellieren die Anzahl der vom Erstligisten geschossenen Tore als $\mathcal{B}(20, 1/10)$-verteilte Zufallsvariable X, und die Anzahl der Tore des Drittligisten als $\mathcal{B}(10, 1/20)$-verteilte Zufallsvariable Y auf einem WR $(\Omega, \mathcal{A}, P)$. Wir nehmen an, dass X und Y unabhängig sind.

Der Erstligist führt nach 90 Minuten, falls das Ereignis $A := \{X > Y\}$ eintritt. Beachte: A lässt sich disjunkt zerlegen in

$$A = \left(\bigcup_{n=11}^{20} \{X = n\} \right) \cup \left(\bigcup_{n=1}^{10} (\{X = n\} \cap \{Y \leq n-1\}) \right).$$

Aus der endlichen Additivität von P und der Unabhängigkeit von X und Y folgt

$$\begin{aligned}
P(A) &= \sum_{n=11}^{20} P(X = n) + \sum_{n=1}^{10} P(\{X = n\} \cap \{Y \leq n-1\}) \\
&= \sum_{n=11}^{20} P(X = n) + \sum_{n=1}^{10} P(X = n) P(Y \leq n-1) \\
&= \sum_{n=11}^{20} \binom{20}{n} \left(\frac{1}{10}\right)^n \left(\frac{9}{10}\right)^{20-n} \\
&\quad + \sum_{n=1}^{10} \left(\binom{20}{n} \left(\frac{1}{10}\right)^n \left(\frac{9}{10}\right)^{20-n} \left(\sum_{k=0}^{n-1} \binom{10}{k} \left(\frac{1}{20}\right)^k \left(\frac{19}{20}\right)^{10-k} \right) \right) \\
&\approx 0,75.
\end{aligned}$$

Wendet man Funktionen auf unabhängige Zufallsvariablen an, so geht die Unabhängigkeit nicht verloren. Genauer gilt:

Lemma 6.18. *Sei $X_1, \ldots, X_n$ eine unabhänige Familie von Zufallsvariablen mit Werten in $\mathbb{R}$. Des Weiteren seien $g_1, \ldots, g_n$ reelle Funktionen mit der Eigenschaft, dass Urbilder von Mengen in $\mathcal{B}$ wieder in $\mathcal{B}$ liegen. Dann ist auch die Familie $g_1(X_1), \ldots, g_n(X_n)$ unabhängig.*

Beweis. Sei $A_i \in \mathcal{B}$ für alle $i \in \{1, \ldots, n\}$. Dann gilt

$$\begin{aligned} P\left(\bigcap_{i=1}^{n} \{g_i(X_i) \in A_i\}\right) &= P\left(\bigcap_{i=1}^{n} \{X_i \in g_i^{-1}(A_i)\}\right) \\ &= \prod_{i=1}^{n} P(X_i \in g_i^{-1}(A_i)) \\ &= \prod_{i=1}^{n} P(g_i(X_i) \in A_i). \end{aligned}$$

Also sind $g(X_1), \ldots, g(X_n)$ unabhängig. □

Falls X und Y diskret sind, dann sind auch $X + Y$ und XY diskret. Die Summe bzw. das Produkt zweier absolutstetiger Zufallsvariablen ist allerdings i.A. nicht wieder absolutstetig. Gegenbeispiel: Sei X exponentialverteilt. Dann sind auch $Y = -X$ und $Z = \frac{1}{X}$ absolutstetig. Allerdings sind $X + Y$ und XZ diskret.

Absolutstetigkeit bleibt erhalten, falls die Zufallsvariablen unabhängig sind:

Lemma 6.19. *Sind X und Y unabhängige und absolutstetige Zufallsvariablen, so sind auch $X + Y$ und XY absolutstetig.*

Beweis. Stochastik (4. Semester). □

7 Verteilungsfunktionen

Sei $(\Omega, \mathcal{A}, P)$ ein WR und $X : \Omega \to \mathbb{R}$ eine Zufallsvariable.

Definition 7.1. Die Abbildung $F : \mathbb{R} \to [0, 1]$, $y \mapsto P(X \leq y)$, heißt Verteilungsfunktion (VF) von X.

Bemerkung: Die Verteilungsfunktion bestimmt auf eindeutige Weise die Verteilung von X: Kennt man die VF, dann auch die Verteilung; und umgekehrt, kennt man die Verteilung, dann auch die VF.

Wie lässt sich aus der VF die (Zähl-)Dichte bestimmen?
<u>1. Fall:</u> X ist diskret. Es bezeichne $\mathcal{Y}$ die Menge der Unstetigkeitsstellen von F, der VF von X. Die Menge $\mathcal{Y}$ ist abzählbar - sei $y_1, y_2, \ldots$ eine Aufzählung. Setze $p_k := F(y_k) - \lim_n F(y_k - \frac{1}{n})$. Dann ist $(p_k)_{k \geq 1}$ Zähldichte von X.
<u>2. Fall:</u> X ist absolutstetig mit Dichte f und VF F. Dann ist $F(y) = \int_{-\infty}^{y} f(x)dx$. Nach dem Hauptsatz der Differential- und Integralrechnung gilt $F'(x) = f(x)$.

Beispiel 7.2. *Seien X und Y unabhängig und $\mathcal{U}[0,1]$-verteilt. Was ist die Dichte von $Z := \max\{X, Y\}$?*

Wir bestimmen zunächst die VF von Z. Dazu beachte: für alle $a \in [0,1]$ gilt

$$\begin{aligned} F_Z(a) &:= P(Z \leq a) \\ &= P(\{X \leq a\} \cap \{Y \leq a\}) \\ &= P(X \leq a)P(Y \leq a) \qquad (\textit{Unabh. von } X \textit{ und } Y) \\ &= a^2. \end{aligned}$$

Wir erhalten die Dichte, indem wir F_Z ableiten: $F_Z'(a) = 2a$ für alle $a \in (0,1)$. Also hat Z eine absolutstetige Verteilung mit Dichte

$$f(x) = \begin{cases} 2x, & x \in [0,1], \\ 0, & \textit{sonst.} \end{cases}$$

Satz 7.3 (Eigenschaften von VF)**.** *Sei $X : \Omega \to \mathbb{R}$ eine ZV und F die VF von X. Dann gilt:*

(i) F ist nicht-fallend,

(ii) F ist rechtsstetig,

(iii) $\lim_{y \downarrow -\infty} F(y) = 0$ und $\lim_{y \uparrow \infty} F(y) = 1$.

Proof. (i) Seien y, $z \in \mathbb{R}$ mit $y \leq z$. Dann gilt $\{X \leq y\} \subset \{X \leq z\}$. Aus der Monotonie von P (siehe Eig. (3) in Satz 3.2) folgt $P(X \leq y) \leq P(X \leq z)$, und somit die Monotonie von F.

(ii) Sei nun $y \in \mathbb{R}$. Setze $A_n := \{X \in]y, y + \frac{1}{n}]\}$. Beachte: A_n ist absteigend und $\bigcap_{n \geq 1} A_n = \emptyset$. Somit folgt mit Lemma 3.5

$$\lim_n (F(y + \frac{1}{n}) - F(y)) = \lim_n P(A_n) = P(\emptyset) = 0. \tag{7.1}$$

Da F monoton ist, folgt aus (7.1) für beliebige Folgen $y_n \downarrow y$, dass $\lim_n F(y_n) = F(y)$. Also ist F rechtsstetig in y. Da y beliebig gewählt war, ist F überall rechtsstetig.

(iii) Betrachte die absteigende Folge $B_n = \{X \leq -n\}$. Beachte: $\bigcap_{n \geq 1} B_n = \emptyset$. Somit folgt aus Lemma 3.5

$$\lim_{n \to -\infty} F(-n) = \lim_{n \to \infty} P(B_n) = P(\emptyset) = 0.$$

Des Weiteren betrachte die absteigende Folge $C_n = \{X > n\}$. Wieder gilt $\bigcap_{n\geq 1} C_n = \emptyset$. Folglich

$$\lim_{n\to\infty} F(n) = \lim_{n\to\infty} (1 - P(C_n)) = 1.$$

Da F monoton ist, gilt also $\lim_{y\downarrow -\infty} F(y) = 0$ und $\lim_{y\uparrow\infty} F(y) = 1$. $\square$

Bemerkung: Man kann zeigen, dass jede Funktion F mit den Eigenschaften (i), (ii) und (iii) aus Satz 7.3 Verteilungsfunktion einer Zufallsvariablen X ist (siehe Satz 7.6 unten). Man bezeichnet deshalb jede Funktion mit (i), (ii) und (iii) als Verteilungsfunktion (ohne Bezug auf eine ZV).

Definition 7.4. Sei F eine VF. Die (verallgemeinerte) inverse Verteilungsfunktion (IFV) von F ist definiert durch

$$F^{-1}(t) = \inf\{x \in \mathbb{R} : F(x) \geq t\}, \qquad t \in [0,1].$$

Hierbei sei $\inf \emptyset = +\infty$.

Lemma 7.5. *Sei F eine VF mit inverser Verteilungsfunktion F^{-1}. Es gilt:*

a) F^{-1} ist nicht-fallend;

b) $F^{-1}(t) \leq x \quad \Longleftrightarrow \quad t \leq F(x)$;

c) $F^{-1}(F(x)) \leq x$;

d) $F(F^{-1}(t)) \geq t$, falls $F^{-1}(t) \in \mathbb{R}$.

Beweis. a) folgt aus der Monotonie von F.
b) $\underline{\Longrightarrow}$: Es gelte $F^{-1}(t) \leq x$. Dann ist $F(x+\varepsilon) \geq t$ für alle $\varepsilon > 0$. Wegen der Rechtsstetigkeit von F gilt dann auch $F(x) \geq t$.
$\underline{\Longleftarrow}$: Es gelte $t \leq F(x)$. Dann ist $F^{-1}(t) \leq x$.
c) Es gilt $F(x) \leq F(x)$. Mit der Rückrichtung von b) folgt $F^{-1}(F(x)) \leq x$.
d) Es gilt $F^{-1}(t) \leq F^{-1}(t)$. Mit der Hin-Richtung von b) folgt $t \leq F(F^{-1}(t))$. $\square$

Satz 7.6. *Sei F eine VF und X eine $\mathcal{U}[0,1]$-verteilte Zufallsvariable. Dann ist $Y := F^{-1}(X)$ eine Zufallsvariable mit VF F.*

Beweis. Beachte: $P(X \in [0,1]) = 1$. Deshalb können wir annehmen, dass X nur Werte im Intervall $[0,1]$ annimmt und Y für alle $\omega \in \Omega$ definiert ist.

Sei nun G die Verteilungsfunktion von X. Es gilt

$$G(x) = \begin{cases} 0, & x \leq 0, \\ x, & x \in (0,1), \\ 1, & x \geq 1. \end{cases}$$

Für alle $y \in \mathbb{R}$ erhalten wir

$$\begin{aligned} P(Y \leq y) &= P(F^{-1}(X) \leq y) \\ &= P(X \leq F(y)) && \text{(Lemma 7.5, b))} \\ &= G(F(y)) \\ &= F(y). \end{aligned}$$

□

In vielen Programmbibiliotheken finden sich Funktionen, die auf $[0, 1]$ gleichverteilte (Pseudo-) Zufallszahlen generieren (in der numpy-Bibliothek: random.rand).

Sei rand() eine Funktion, die eine $\mathcal{U}[0, 1]$-verteilte Zufallszahl erzeugt. Sei F eine Verteilungsfunktion. Nach Satz 7.6 erzeugt dann $F^{-1}(\text{rand}())$ eine Zufallszahl mit VF F.

8 Erwartungswerte von Zufallsvariablen

Ziel des Abschnitts: Definition und Eigenschaften von Erwartungswerten.

Zunächst betrachten wir diskrete Zufallsvariablen, d.h. Zufallsvariablen mit höchstens abzählbar vielen Werten.

Sei $(\Omega, \mathcal{A}, P)$ ein WR.

Definition 8.1. Sei $X : \Omega \to \mathbb{R}$ eine Zufallsvariable mit Werten nur in einer endlichen Menge $\{y_1, y_2, \ldots, y_N\}$. Der Erwartungswert (EW) von X ist dann definiert durch

$$E(X) := \sum_{i=1}^{N} y_i P(X = y_i). \tag{8.1}$$

Falls $X : \Omega \to \mathbb{R}$ abzählbar unendlich viele Werte $y_1, y_2, \ldots$ annimmt, dann ist es naheliegend den Erwartungswert zu definieren durch

$$E(X) := \sum_{i=1}^{\infty} y_i P(X = y_i). \tag{8.2}$$

Aber **Vorsicht:** falls unendlich viele y_i positiv und unendlich viele negativ sind, dann kann es sein, dass der Reihenlimes in (8.2) nicht definiert ist oder von der Reihenfolge der Summation abhängt.

Definition 8.2. Sei $X : \Omega \to \mathbb{R}$ eine Zufallsvariable mit Werten in einer abzählbaren Menge $\{y_1, y_2, \ldots\}$. Man sagt, dass X integrierbar ist, falls die Reihe $\sum_{i=1}^{\infty} y_i P(X = y_i)$ absolut konvergent ist. In diesem Fall ist dann der Erwartungswert (EW) von X definiert durch (8.2).

Bemerkung. Erinnerung: bei absolut konvergenten Reihen spielt die Reihenfolge der Summation keine Rolle.

Beispiel 8.3. *Sei X eine Zufallsvariable mit $P(X = 3) = \frac{1}{2}$, $P(X = 5) = \frac{1}{3}$ und $P(X = 7) = \frac{1}{6}$. Dann gilt*

$$E(X) = 3\frac{1}{2} + 5\frac{1}{3} + 7\frac{1}{6} = \frac{13}{3}.$$

Beispiel 8.4. *Sei X geometrisch verteilt mit Parameter $p \in (0, 1]$. (Erinnerung: dies bedeutet $P(X = k) = (1 - p)^{k-1}p$ für alle $k \in \{1, 2, 3, \ldots\}$.)*

Zunächst beachte: $\sum_{k=1}^{\infty} k(1 - p)^{k-1}p$ ist absolut konvergent (dies folgt zB aus dem Quotienten-Kriterium). Also ist X integrierbar.

Was ist $E(X)$? Beachte zunächst

$$\sum_{k=1}^{\infty} k(1 - p)^{k-1}p = p \sum_{k=1}^{\infty} k(1 - p)^{k-1}$$

und

$$\begin{aligned}
\sum_{k=1}^{\infty} k(1 - p)^{k-1} &= -\frac{d}{dp}\left(\sum_{k=1}^{\infty}(1 - p)^k\right) \\
&= -\frac{d}{dp}\left(\frac{1}{1 - (1 - p)} - 1\right) \\
&= -\frac{d}{dp}\left(\frac{1}{p} - 1\right) = \frac{1}{p^2}.
\end{aligned}$$

Hieraus folgt, dass der Erwartungswert gegeben ist durch $E(X) = \frac{1}{p}$.

Beispiel 8.5. *Sei X eine Zufallsvariable mit $P(X = 2^n) = \frac{1}{2^n}$ für $n \in \mathbb{N}$. Beachte: $\sum_{n=1}^{\infty} 2^n P(X = 2^n) = \infty$. Also ist X nicht integrierbar.*

Wir leiten uns nun heuristisch die Definition des Erwartungswerts von absolutstetigen Zufallsvariablen her. Sei dazu X eine Zufallsvariable mit Dichte f, d.h. für alle $a < b$ gelte

$$P(X \in [a, b)) = \int_a^b f(x)dx.$$

Wir approximieren X mit diskreten Zufallsvariablen wie folgt: für alle $n \in \mathbb{N}$ und $\omega \in \Omega$ setze

$$X_n(\omega) := \frac{k}{n}, \text{ falls } X(\omega) \in \left[\frac{k}{n}, \frac{k+1}{n}\right), k \in \mathbb{Z}.$$

Dann gilt $\lim_n X_n(\omega) = X(\omega)$. Wogegen konvergieren die Erwartungswerte von X_n, falls $n \to \infty$? Dazu beachte:

$$\begin{aligned} E(X_n) &= \sum_{k\in\mathbb{Z}} \frac{k}{n} P\left(X_n = \frac{k}{n}\right) \\ &= \sum_{k\in\mathbb{Z}} \frac{k}{n} P\left(X \in \left[\frac{k}{n}, \frac{k+1}{n}\right)\right) \\ &= \sum_{k\in\mathbb{Z}} \int_{k/n}^{(k+1)/n} \frac{k}{n} f(x)dx. \end{aligned} \tag{8.3}$$

Die Summe in (8.3) erinnert an eine Riemann-Summe. Man kann nun zeigen, dass diese Summe gegen $\int_{-\infty}^{\infty} xf(x)dx$ konvergiert, sofern das uneigentliche Riemann-Integral $\int_{-\infty}^{\infty} |xf(x)|dx$ konvergent ist. Deshalb:

Definition 8.6. Sei X eine Zufallsvariable mit Dichte f. Man sagt, dass X integrierbar ist, falls $|xf(x)|$ uneigentlich Riemann-integrierbar ist. In diesem Fall ist der Erwartungswert definiert durch

$$E(X) := \int_{-\infty}^{\infty} xf(x)dx.$$

Beispiel 8.7. *Sei X eine $\mathcal{U}[a,b]$-verteilte Zufallsvariable, wobei $a < b$. Wie groß ist $E(X)$? Erinnerung: die Dichte von X ist $f(x) = \frac{1}{b-a}1_{[a,b]}(x)$. Also gilt*

$$\begin{aligned} E(X) &= \int_a^b x\frac{1}{b-a}dx = \frac{1}{b-a}\left(\frac{1}{2}x^2\Big|_a^b\right) = \frac{1}{2}\frac{1}{b-a}\left(b^2 - a^2\right) \\ &= \frac{1}{2}\frac{1}{b-a}(b+a)(b-a) \\ &= \frac{b+a}{2}. \end{aligned}$$

Beispiel 8.8. *Sei X $\mathcal{N}(\mu, v)$-verteilt. Dann gilt:*

$$\begin{aligned}
E(X) &= \int_{-\infty}^{\infty} \frac{x}{\sqrt{2\pi v}} e^{-\frac{(x-\mu)^2}{2v}} dx \\
&= \int_{-\infty}^{\infty} \frac{x-\mu}{\sqrt{2\pi v}} e^{-\frac{(x-\mu)^2}{2v}} dx + \mu \int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi v}} e^{-\frac{(x-\mu)^2}{2v}} dx \\
&= \int_{-\infty}^{\infty} \frac{y}{\sqrt{2\pi v}} e^{-\frac{y^2}{2v}} dy + \mu \\
&= \int_{0}^{\infty} \frac{y}{\sqrt{2\pi v}} e^{-\frac{y^2}{2v}} dy - \int_{0}^{\infty} \frac{y}{\sqrt{2\pi v}} e^{-\frac{y^2}{2v}} dy + \mu \\
&= \mu.
\end{aligned}$$

Also ist μ der Erwartungswert von X.

Satz 8.9. *Sei $g : \mathbb{R} \to \mathbb{R}$ eine Funktion und $X : \Omega \to \mathbb{R}$ eine diskrete Zufallsvariable mit Werten in $\{y_1, y_2, \ldots\}$. Falls $g(X)$ integrierbar ist, dann gilt*

$$E[g(X)] = \sum_{i=1}^{\infty} g(y_i) P(X = y_i).$$

Beweis. Setze $Z := g(X)$. Dann ist Z ebenfalls diskret und wir bezeichnen mit $\{a_1, a_2, \ldots\}$ die Menge möglicher Werte für Z. Beachte: für ein a_k kann es mehrere y_i geben mit $g(y_i) = a_k$. Wir definieren deshalb $J(a_k) = \{j \geq 1 : g(y_j) = a_k\}$. Dann gilt

$$\begin{aligned}
\sum_{j \in J(a_k)} g(y_j) P(X = y_j) &= a_k \sum_{j \in J(a_k)} P(X = y_j) \\
&= a_k P\left(\bigcup_{j \in J(a_k)} \{X = y_j\} \right) = a_k P(Z = a_k).
\end{aligned}$$

Folglich,

$$\begin{aligned}
E(Z) &= \sum_{k=1}^{\infty} a_k P(Z = a_k) = \sum_{k=1}^{\infty} \sum_{j \in J(a_k)} g(y_j) P(X = y_j) \\
&= \sum_{j=1}^{\infty} g(y_j) P(X = y_j).
\end{aligned}$$

□

Ein analoges Resultat gilt auch für Zufallsvariablen mit Dichten:

Satz 8.10. *Sei $g : \mathbb{R} \to \mathbb{R}$ eine Funktion und $X : \Omega \to \mathbb{R}$ eine Zufallsvariable mit Dichte f. Falls $g(X)$ eine integrierbare Zufallsvariable ist, dann gilt*

$$E[g(X)] = \int_{-\infty}^{\infty} g(x)f(x)dx.$$

Der Satz 8.10 wird in der Stochastik-Vorlesung im Sommersem. 2024 bewiesen.

Beispiel 8.11. *Sei X Poisson-verteilt zum Parameter $\lambda \in (0, \infty)$ und $g(x) = x^2$. Dann gilt*

$$\begin{aligned} E(X^2) &= \sum_{k=0}^{\infty} k^2 e^{-\lambda} \frac{\lambda^k}{k!} \\ &= e^{-\lambda}\lambda \sum_{k=1}^{\infty} \frac{k\lambda^{k-1}}{(k-1)!} \\ &= e^{-\lambda}\lambda \, \frac{d}{d\lambda}\left(\sum_{k=1}^{\infty} \frac{\lambda^k}{(k-1)!}\right). \end{aligned} \tag{8.4}$$

Beachte: $\sum_{k=1}^{\infty} \frac{\lambda^k}{(k-1)!} = \lambda \sum_{k=1}^{\infty} \frac{\lambda^{k-1}}{(k-1)!} = \lambda e^{\lambda}$ *und somit*

$$\frac{d}{d\lambda}\left(\sum_{k=1}^{\infty} \frac{\lambda^k}{(k-1)!}\right) = \frac{d}{d\lambda}\left(\lambda e^{\lambda}\right) = e^{\lambda} + \lambda e^{\lambda}.$$

Mit (8.4) *erhalten wir also*

$$E(X^2) = e^{-\lambda}\lambda(e^{\lambda} + \lambda e^{\lambda}) = \lambda + \lambda^2.$$

Beispiel 8.12. *Sei X eine $\mathcal{U}[0,1]$-verteilte Zufallsvariable und $g(x) = x^3$. Dann gilt*

$$E(X^3) = \int_{-\infty}^{\infty} x^3 1_{[0,1]}(x)dx = \int_0^1 x^3 dx = \frac{1}{4}.$$

Wir kommen nun zu weiteren Eigenschaften von Erwartungswerten.

Satz 8.13. *Seien X und Y zwei integrierbare Zufallsvariablen (beide diskret oder beide mit Dichten) und es sei $a \in \mathbb{R}$. Dann gilt:*

a) Monotonie:

$$X(\omega) \leq Y(\omega) \text{ für alle } \omega \in \Omega \quad \Longrightarrow \quad E(X) \leq E(Y)$$

b) Linearität:

$$E(X+Y) = E(X) + E(Y)$$
$$E(aX) = aE(X)$$

c) X und Y unabhängig $\implies$ XY ist integr. und $E(XY) = E(X)E(Y)$.

Beweisskizze von Satz 8.13. Eigenschaften a) und b) gelten, weil Summen / Integrale monoton und linear sind.

c) Wir betrachten nur den Fall, wo X und Y nur endlich viele Werte annehmen. Sei $\{a_1, \ldots, a_N\}$ die Menge möglicher Werte von X und $\{b_1, \ldots, b_M\}$ die Menge möglicher Werte von Y. Dann gilt

$$\begin{aligned}
E(XY) &= E\left(\sum_{i=1}^{N}\sum_{j=1}^{M} XY 1_{\{X=a_i\}} 1_{\{Y=b_j\}}\right) \\
&\overset{b)}{=} \sum_{i=1}^{N}\sum_{j=1}^{M} E\left(XY 1_{\{X=a_i\}} 1_{\{Y=b_j\}}\right) \\
&= \sum_{i=1}^{N}\sum_{j=1}^{M} E\left(a_i b_j 1_{\{X=a_i\}} 1_{\{Y=b_j\}}\right) \\
&\overset{b)}{=} \sum_{i=1}^{N}\sum_{j=1}^{M} a_i b_j E\left(1_{\{X=a_i\}} 1_{\{Y=b_j\}}\right) \\
&= \sum_{i=1}^{N}\sum_{j=1}^{M} a_i b_j P(\{X=a_i\} \cap \{Y=b_j\}) \\
&= \sum_{i=1}^{N}\sum_{j=1}^{M} a_i b_j P(X=a_i) P(Y=b_j) \qquad \text{(Unabhängigkeit)} \\
&= \left(\sum_{i=1}^{N} a_i P(X=a_i)\right)\left(\sum_{j=1}^{M} b_j P(Y=b_j)\right) \\
&= E(X)E(Y).
\end{aligned}$$

□

Beispiel 8.14. *Sei $X_1, \ldots, X_n$ eine unabhängige Familie von Bernoulli-verteilten Zufallsvariablen mit Parameter $p \in (0,1)$. Dann ist $S_n := \sum_{i=1}^{n} X_i$ eine $\mathcal{B}(n,p)$-verteilte Zufallsvariable (vgl. Herleitung der Binomialverteilung). Nach Satz 8.13 b) gilt*

$$E(S_n) = \sum_{i=1}^{n} E(X_i) = \sum_{i=1}^{n} (1 * p + 0 * (1-p)) = np.$$

Also ist der Erwartungswert einer $\mathcal{B}(n,p)$-verteilten Zufallsvariable np.

Anmerkungen zur Integrierbarkeit von Zufallsvariablen

In den Sätzen 8.9 und 8.10 wurde angenommen, dass $g(X)$ integrierbar ist. Wie lässt sich das überprüfen?

Lemma 8.15. *Sei $g : \mathbb{R} \to \mathbb{R}$ und $X : \Omega \to \mathbb{R}$ eine diskrete Zufallsvariable mit Werten in $\{y_1, y_2, \ldots\}$. Falls $\sum_{j=1}^{\infty} |g(y_j)| P(X = y_j) < \infty$, dann ist $g(X)$ integrierbar.*

Beweis. Wir verwenden die Notation aus dem Beweis von Satz 8.9. Falls $\sum_{j=1}^{\infty} g(y_j) P(X = y_j)$ absolut konvergent ist, dann ist auch die umsortierte Reihe $\sum_{k=1}^{\infty} \sum_{j \in J(a_k)} g(y_j) P(X = y_j)$ absolut konvergent, und folglich auch $\sum_{k=1}^{\infty} a_k P(Z = a_k)$. Somit ist $g(X)$ integrierbar. □

Lemma 8.16. *Sei $g : \mathbb{R} \to \mathbb{R}$ und $X : \Omega \to \mathbb{R}$ eine absolutstetige Zufallsvariable mit Dichte f, sodass $g(X)$ eine Zufallsvariable ist. Falls $x \mapsto |g(x)| f(x)$ uneigentlich Riemann-integrierbar ist (d.h. $\lim_{\alpha \to \infty, \beta \to -\infty} \int_\beta^\alpha |g(x)| f(x) dx$ existiert in $\mathbb{R}$), dann ist $g(X)$ integrierbar.*

Beweis. Stochastik (4. Semester). □

Bemerkung. Mit Lemma 8.15 lässt sich zeigen, dass X^2 aus Beispiel 8.11 integrierbar ist; und mit Lemma 8.16, dass X^3 aus Beispiel 8.12 integrierbar ist.

Die nächsten Lemmata stellen weitere nützliche Eigenschaften von integrierbaren Zufallsvariablen zusammen.

Lemma 8.17. *Sei X eine Zufallsvariable. Gibt es eine nicht-negative, integrierbare Zufallsvariable Y mit*

$$\forall \omega \in \Omega : |X(\omega)| \leq Y(\omega),$$

so ist auch X integrierbar.

Beweis für den diskreten Fall. Sei $x_1, x_2, \ldots$ eine Aufzählung der Werte von X und $y_1, y_2, \ldots$ ein Aufzählung der Werte von Y. Es gelte $|X| \leq Y$. Dann

folgt

$$\begin{aligned}
\infty > \sum_{j=1}^{\infty} y_j P(Y = y_j) &= \sum_{j=1}^{\infty}\sum_{i=1}^{\infty} y_j P(\{Y = y_j\} \cap \{X = x_i\}) \\
&\geq \sum_{j=1}^{\infty}\sum_{i=1}^{\infty} |x_i| P(\{Y = y_j\} \cap \{X = x_i\}) \\
&\qquad\qquad (\text{weil } \{Y = y_j\} \cap \{X = x_i\} = \emptyset, \text{ falls } |x_i| > y_j) \\
&= \sum_{i=1}^{\infty} |x_i| \sum_{j=1}^{\infty} P(\{Y = y_j\} \cap \{X = x_i\}) \\
&= \sum_{i=1}^{\infty} |x_i| P(X = x_i).
\end{aligned}$$

Also ist X integrierbar. □

Lemma 8.18. *Seien X und Y zwei integrierbare Zufallsvariablen (beide diskret oder absolutstetig). Dann gilt:*

a) Für alle $a \in \mathbb{R}$ ist auch aX integrierbar.

b) $X + Y$ ist integrierbar.

c) Sind X^2 und Y^2 integrierbar, dann ist auch XY integrierbar.

Beweisskizze. a) Übung.

b) Wir betrachten nur den diskreten Fall. Die möglichen Werte von X seien $x_1, x_2, \ldots$, die von Y seien $y_1, y_2, \ldots$, und die von $X+Y$ seien $a_1, a_2, \ldots$. Dann gilt

$$\begin{aligned}
\sum_{k=1}^{\infty} |a_k| P(X + Y = a_k) &= \sum_{i=1}^{\infty}\sum_{i=1}^{\infty} |x_i + y_j| P(\{Y = y_j\} \cap \{X = x_i\}) \\
&\leq \sum_{i=1}^{\infty}\sum_{i=1}^{\infty} (|x_i| + |y_j|) P(\{Y = y_j\} \cap \{X = x_i\}) \\
&= \sum_{i=1}^{\infty} |x_i| P(X = x_i) + \sum_{i=1}^{\infty} |y_j| P(Y = y_j) \\
&< \infty,
\end{aligned}$$

da X und Y integrierbar sind.

c) Beachte: $|XY| \leq \frac{1}{2}(X^2 + Y^2)$. (Begründung hierfür: für alle $x, y \in \mathbb{R}$ gilt $\frac{1}{2}(x^2 - 2xy + y^2) = \frac{1}{2}(x - y)^2 \geq 0$; also gilt $xy \leq \frac{1}{2}(x^2 + y^2)$.)

Mit a) und b) folgt, dass $\frac{1}{2}(X^2 + Y^2)$ integrierbar ist. Mit Lemma 8.17 folgt, dass auch das Produkt XY integrierbar ist. □

Bemerkung. 1) Beachte: Lemma 8.18 a),b) stellt sicher, dass $E(X+Y)$ und $E(aX)$ in Satz 8.13 b) definiert sind.

2) Strenggenommen müssten wir in Satz 8.13 b),c) und Lemma 8.17 b), c) annehmen, dass $X+Y$ bzw XY diskret bzw absolutstetig ist, da wir den Erwartungswert nur für diskrete bzw absolutstetige Zufallsvariablen definiert haben. Man kann allerdings den Erwartungswert auf größere Klassen von Zufallsvariablen erweitern, sodass diese Annahme nicht benötigt wird.

9 Varianz und Kovarianz

Ziel: Maße für die Streuung und den Zusammenhang von Zufallsvariablen.

Sei $(\Omega, \mathcal{A}, P)$ ein WR.

Definition 9.1. Eine Zufallsvariable X heißt quadrat-integrierbar, falls X^2 integrierbar ist.

Lemma 9.2. *Sei X eine quadrat-integrierbare Zufallsvariable. Dann sind auch X und $(X-E(X))^2$ integrierbar.*

Beweis. 1. Aus der Annahme und Lemma 8.18 folgt, dass X^2+1 integrierbar ist. Wegen $|X|(\omega) \leq (1+X^2(\omega))$, $\omega \in \Omega$, folgt dann wg. Lemma 8.17, dass auch $|X|$ integrierbar ist.

2. Es gilt $(X-E[X])^2 \leq 2(X^2+E[X]^2)$. Da die rechte Seite integrierbar ist, ist auch die linke Seite integrierbar. □

Definition 9.3. Sei X eine quadrat-integrierbare Zufallsvariable. Dann ist die Varianz von X definiert durch

$$\mathrm{Var}(X) := E\left[(X-E(X))^2\right].$$

Die Standardabweichung von X ist dann

$$\mathrm{Stabw}(X) := \sqrt{\mathrm{Var}(X)}.$$

Beispiel 9.4. *Sei X $\mathcal{N}(\mu, v)$-verteilt, wobei $\mu \in \mathbb{R}$ und $v \in (0,\infty)$. In Beispiel 8.8 haben wir gezeigt, dass $E(X)=\mu$. Wir berechnen nun folgendes Integral:*

$$\begin{aligned}
&\int_{-\infty}^{\infty} (y-\mu)^2 \frac{1}{\sqrt{2\pi v}} e^{-\frac{(y-\mu)^2}{2v}} dy \\
=&\int_{-\infty}^{\infty} z^2 \frac{1}{\sqrt{2\pi}} e^{-\frac{z^2}{2}} v \; dz && \left(z = \frac{y-\mu}{\sqrt{v}}\right) \\
=&\left(-z \frac{1}{\sqrt{2\pi}} e^{-\frac{z^2}{2}} v \Big|_{-\infty}^{\infty}\right) - \int_{-\infty}^{\infty} (-1) \frac{1}{\sqrt{2\pi}} e^{-\frac{z^2}{2}} v \; dz && (\textit{part. Integration}) \\
=&v.
\end{aligned}$$

Also ist $y \mapsto (y-\mu)^2 \frac{1}{\sqrt{2\pi v}} e^{-\frac{(y-\mu)^2}{2v}}$ *uneigentlich Riemann-integrierbar. Mit Lemma 8.16 folgt, dass* $(X-\mu)^2$ *integrierbar ist. Folglich, mit Satz 8.10,*

$$Var(X) = E[(X-\mu)^2] = \int_{-\infty}^{\infty} (y-\mu)^2 \frac{1}{\sqrt{2\pi v}} e^{-\frac{(y-\mu)^2}{2v}} dy = v.$$

Also ist v *die Varianz von* X.

Satz 9.5 (Eigenschaften der Varianz)**.** *Sei* X *eine quadrat-integrierbare Zufallsvariable (diskret oder mit Dichte) und* $a \in \mathbb{R}$. *Dann gilt:*

a) $Var(X) = E(X^2) - (E(X))^2$;

b) $Var(aX) = a^2\, Var(X)$;

c) $Var(X) = 0 \iff X$ *ist konstant, d.h. es ex.* $c \in \mathbb{R}$ *mit* $P(X = c) = 1$.

Beweis. a)

$$\begin{aligned}
\mathrm{Var}(X) &= E[(X - E(X))^2] \\
&= E[X^2 - 2XE(X) + (E(X))^2] \\
&= E[X^2] - 2E(X)E(X) + (E(X))^2 \qquad \text{(Satz 8.13 b)} \\
&= E(X^2) - (E(X))^2.
\end{aligned}$$

b)

$$\begin{aligned}
\mathrm{Var}(aX) &= E[(aX - E(aX))^2] \\
&= E[(aX - aE(X))^2] \qquad \text{(Satz 8.13 b)} \\
&= E[a^2(X - E(X))^2] \\
&= a^2 E[(X - E(X))^2] \qquad \text{(Satz 8.13 b)} \\
&= a^2 \mathrm{Var}(X).
\end{aligned}$$

c) $\underline{\Longleftarrow:}$ $P(X = c) = 1$ impliziert $E(X) = c$. Also $P(X - E(X) = 0) = 1$ und somit auch $P((X - E(X))^2 = 0) = 1$, woraus folgt, dass $\mathrm{Var}(X) = E[(X - E(X))^2] = 0$.

$\underline{\Longrightarrow:}$ $\mathrm{Var}(X) = 0$ impliziert $P[(X - E(X))^2 = 0] = 1$. Es folgt $P(X = E(X)) = 1$, d.h. X ist konstant. □

Korollar 9.6. *Die Standardabweichung ist positiv homogen, d.h. für alle* $a \in [0, \infty)$ *und alle quadrat-integrierbaren Zufallsvariablen* X *gilt*

$$Stabw(aX) = a\, Stabw(X).$$

Beispiel 9.7. *Sei X Poisson-verteilt zum Parameter $\lambda \in (0, \infty)$. Von Übungsblatt 4, Präsenzaufgabe 2, wissen wir: $E(X) = \lambda$. Aus Beispiel 8.11 wissen wir $E(X^2) = \lambda + \lambda^2$. Also gilt für die Varianz*

$$Var(X) = E(X^2) - (E(X))^2 = \lambda + \lambda^2 - \lambda^2 = \lambda.$$

Satz 9.8. *Seien X und Y zwei unabhängige, quadrat-integrierbare Zufallsvariablen (beide diskret oder beide absolutstetig). Dann gilt*

$$Var(X + Y) = Var(X) + Var(Y).$$

Beweis. Zunächst beachte

$$E[(X + Y)^2] = E[X^2 + 2XY + Y^2] = E(X^2) + 2E(XY) + E(Y^2).$$

Nach Satz 8.13 c) gilt: $E(XY) = E(X)E(Y)$. Also

$$E[(X + Y)^2] = E(X^2) + 2E(X)E(Y) + E(Y^2).$$

Weiterhin gilt

$$(E(X + Y))^2 = (E(X) + E(Y))^2 = (E(X))^2 + 2E(X)E(Y) + (E(Y))^2.$$

Durch 3-maliges Anwenden von Satz 9.5 a) erhalten wir

$$\begin{aligned}
\mathrm{Var}(X + Y) &= E[(X + Y)^2] - (E(X + Y))^2 \\
&= E(X^2) + 2E(X)E(Y) + E(Y^2) - (E(X))^2 - 2E(X)E(Y) - (E(Y))^2 \\
&= E(X^2) - (E(X))^2 + E(Y^2) - (E(Y))^2 \\
&= \mathrm{Var}(X) + \mathrm{Var}(Y).
\end{aligned}$$

□

Beispiel 9.9. *Seien $X_1, \ldots, X_n$ unabhängig und Bernoulli-verteilt mit Parameter $p \in [0, 1]$ und setze $S_n := \sum_{i=1}^n X_i$. Dann ist S_n $\mathcal{B}(n, p)$-verteilt, und nach Beispiel 8.14 gilt $E(S_n) = np$. Was ist die Varianz von X?*

Mit Satz 9.8 folgt

$$Var(S_n) = Var(X_1) + Var(X_2 + \cdots + X_n) = \cdots = \sum_{i=1}^n Var(X_i). \tag{9.1}$$

Da $E(X_i) = p$, gilt

$$Var(X_i) = E[(X_i - p)^2] = (1 - p)^2 p + (-p)^2(1 - p) = p(1 - p).$$

Mit (9.1) *erhalten wir*

$$Var(S_n) = np(1 - p).$$

Die Standardabweichung einer $\mathcal{B}(n, p)$-verteilten ZV ist also $\sqrt{np(1 - p)}$.

Definition 9.10. Seien X und Y zwei quadrat-integrierbare Zufallsvariablen mit Werten in $\mathbb{R}$. Die Kovarianz von X und Y ist definiert durch

$$\mathrm{Cov}(X,Y) := E\left[(X-E(X))(Y-E(Y))\right].$$

X und Y heißen *unkorreliert*, falls $\mathrm{Cov}(X,Y)=0$.

Bemerkung. Beachte: $|(X-E(X))(Y-E(Y))| \leq (X-E(X))^2 + (Y-E(Y))^2$. Also gilt $E|(X-E(X))(Y-E(Y))| \leq \mathrm{Var}(X)+\mathrm{Var}(Y) < \infty$. Also ist das Produkt $(X-E(X))(Y-E(Y))$ integrierbar, und insbesondere dessen EW definiert.

Bis zum Ende von diesem Abschnitt nehmen wir an, dass alle betrachteten Zufallsvariablen reellwertig und quadrat-integrierbar sind. Insbesondere sind dann die Varianzen und Kovarianzen immer definiert.

Satz 9.11 (Eigenschaften der Kovarianz)**.** *Seien X, Y und Z Zufallsvariablen und $a, b \in \mathbb{R}$. Dann gilt:*

(K1) Symmetrie: $Cov(X,Y) = Cov(Y,X)$;

(K2) Bi-Linearität: $Cov(aX+bY,Z) = aCov(X,Z) + bCov(Y,Z)$;

(K3) $Cov(X,X) = Var(X) \geq 0$;

(K4) $|Cov(X,Y)| \leq Stabw(X)\ Stabw(Y)$;

(K5) $Cov(X,Y) = E(XY) - E(X)E(Y)$;

(K6) X, Y unabhängig $\implies$ $Cov(X,Y) = 0$.

Beweis. (K1) folgt aus der Definition.
(K2) folgt aus der Linearität des Erwartungswerts.
(K3): $\mathrm{Cov}(X,X) = E[(X-E(X))^2] = \mathrm{Var}(X) \geq 0$.
(K4): Die Eigenschaften (K1)-(K3) bedeuten, dass $\mathrm{Cov}(\cdot,\cdot)$ ein Skalarprodukt ist auf dem Vektorraum

$$\left\{X : X \text{ ist ZV mit } E(X)=0 \text{ und } E(X^2)<\infty\right\}.$$

Die Cauchy-Schwarz-Ungleichung für dieses Skalarprodukt ist (K4).
(K5): Mit der Linearität des Erwartungswertes erhalten wir

$$\begin{aligned}\mathrm{Cov}(X,Y) &= E\left[(X-E(X))(Y-E(Y))\right]\\ &= E[XY - E(X)Y - E(Y)X + E(X)E(Y)]\\ &= E(XY) - E(X)E(Y).\end{aligned}$$

(K6): folgt aus (K5) und Satz 8.13 c). □

Vorsicht: X, Y unkorreliert $\not\Longrightarrow$ X, Y unabhängig.
Gegenbeispiel: Aufg. 3, Übungsblatt 5.

Die Kovarianz ist ein nicht-standardisiertes Maß. D.h: skaliert man X mit a, so ändert sich auch die Kovarianz von X und Y um den Faktor a. Ein skalierungsunabhängiges (= standardisiertes) Zusammenhangsmaß erhält man, indem man durch die Standardabweichungen von X und Y dividiert.

Definition 9.12. Seien X und Y zwei Zufallsvariablen mit positiver Standardabweichung. Die Korrelation zwischen X und Y ist definiert durch

$$\mathrm{Corr}(X, Y) := \frac{\mathrm{Cov}(X, Y)}{\mathrm{Stabw}(X)\ \mathrm{Stabw}(Y)}.$$

10 Grenzwertsätze

Definition 10.1. Eine Folge von Zufallsvariablen $X_1, X_2, \ldots$ heißt i.i.d. (independent and identically distributed), falls die Folge unabhängig ist und jedes X_i dieselbe Verteilung hat.

Im Folgenden sei $X_1, X_2, \ldots$ eine i.i.d Folge. Weiterhin gelte, dass die X_i quadrat-integrierbar sind. Damit ist die Varianz aller X_i endlich.

Da alle X_i dieselbe Verteilung haben, gilt $E(X_1) = E(X_2) = \cdots$ und $\mathrm{Var}(X_1) = \mathrm{Var}(X_2) = \cdots$. Wir setzen $\mu := E(X_i)$ und $\sigma := \mathrm{Stabw}(X_i)$.

Wir untersuchen zunächst $S_n := \sum_{i=1}^n X_i$. Solche laufenden Summen kommen in vielen Anwendungen vor. Hier sind ein paar Beispiele:

1) $X_1, X_2, \ldots, X_n$ = gemeldete Schäden (in Euro) von n Versicherungsnehmern. S_n stellt den gemeldeten Gesamtschaden dar.

2) $X_1, X_2, \ldots$ = Ergebnisse beim wiederholten Werfen auf einen Korb. S_n = Anzahl erfolgreicher Korbwürfe nach den ersten n Versuchen.

3) $X_1, X_2, \ldots$ = Anzahl an Bestellungen eines bestimmten Produktes, die an aufeinanderfolgenden Tagen in einem Lager eingehen. S_n = Gesamtzahl an Bestellungen bis zum $n$ten Tag.

Lemma 10.2. *Es gilt*

a) $E(S_n) = \mu n$,

b) $\mathit{Stabw}(S_n) = \sqrt{n}\sigma$.

Beweis. Aus der Linearität des Erwartungswerts folgt

$$E(S_n) = \sum_{i=1}^{n} E(X_i) = n\mu.$$

Da die X_i unabhängig sind, gilt nach Satz 9.8

$$\mathrm{Var}(S_n) = \sum_{i=1}^{n} \mathrm{Var}(X_i) = n\sigma^2.$$

Hieraus folgt, $\mathrm{Stabw}(S_n) = \sigma\sqrt{n}$. □

Bemerkung. Erkenntnisse aus Lemma 10.2:

a) Die Standardabweichung von S_n wächst langsamer als der Erwartungswert.

b) Je größer der pool, desto kleiner der Anteil einzelner X_i an der Standardabweichung von S_n:

$$\frac{\mathrm{Stabw}(S_n)}{n} = \frac{\sigma}{\sqrt{n}} \overset{n\to\infty}{\longrightarrow} 0. \tag{10.1}$$

Die Geschäftsidee von Versicherungsunternehmen und Betreibern großer Lager basiert auf (10.1): Die Standardabweichung ist ein Maß für das Risiko. Durch die Aggregierung unabhängiger Positionen wird das Risiko pro Position kleiner. Man spricht von "risk pooling". Beachte: wegen der positiven Homogenität (siehe Lemma 9.6) ist die St.abweichung als Risikomaß besser geeignet als die Varianz.

Wir untersuchen jetzt den Mittelwert $\frac{1}{n}S_n$. Zunächst beachte:

$$E(\frac{1}{n}S_n) = \frac{1}{n}E(S_n) = \frac{1}{n}n\mu = \mu,$$

und

$$\mathrm{Stabw}(\frac{1}{n}S_n) = \frac{1}{n}\mathrm{Stabw}(S_n) = \frac{\sigma}{\sqrt{n}} \overset{n\to\infty}{\longrightarrow} 0.$$

Die Standardabweichung des Mittelwertes $\frac{1}{n}S_n$ konvergiert gegen 0. Folglich konvergiert $\frac{1}{n}S_n$ gegen den Erwartungswert μ. Genauer:

Satz 10.3 (Schwaches Gesetz der großen Zahl)**.** *Für alle $\varepsilon > 0$ gilt*

$$\lim_{n\to\infty} P\left(\left|\frac{S_n}{n} - \mu\right| > \varepsilon\right) = 0.$$

Für den Beweis von Satz 10.3 verwenden wir folgendes Resultat:

Lemma 10.4 (Ungleichung von Chebyshev)**.** *Sei X eine integrierbare Zufallsvariable und $\delta \in (0, \infty)$. Dann gilt*

$$P(|X| \geq \delta) \leq \frac{E(|X|)}{\delta}. \tag{10.2}$$

Beweis. Es gilt $\delta 1_{\{|X| \geq \delta\}} \leq |X|$. Aus der Monotonie des Erwartungswertes folgt somit

$$E[\delta 1_{\{|X| > \delta\}}] \leq E\left[|X|\right]. \tag{10.3}$$

Für die linke Seite von (10.3) gilt

$$E[\delta 1_{\{|X| > \delta\}}] = \delta P(|X| > \delta).$$

Zusammen mit (10.3) folgt hieraus (10.2). □

Beweis von Satz 10.3. Zunächst beachte

$$P\left(\left|\frac{S_n}{n} - \mu\right| > \varepsilon\right) = P\left(\left|\frac{S_n}{n} - \mu\right|^2 > \varepsilon^2\right).$$

Wir wenden nun auf die rechte Seite die Ungleichung (10.2) an mit $X = \left(\frac{S_n}{n} - \mu\right)^2$ und $\delta = \varepsilon^2$. Damit folgt

$$\begin{aligned} P\left(\left|\frac{S_n}{n} - \mu\right| > \varepsilon\right) &\leq \frac{1}{\varepsilon^2} E\left[\left(\frac{S_n}{n} - \mu\right)^2\right] \\ &= \frac{1}{\varepsilon^2} \mathrm{Var}\left(\frac{S_n}{n}\right) \\ &= \frac{\sigma^2}{\varepsilon^2 n}. \end{aligned} \tag{10.4}$$

Die rechte Seite von (10.4) konvergiert gegen 0, falls $n \to \infty$. □

Satz 10.3 verwendet folgenden Konvergenzbegriff:

Definition 10.5. Eine Folge $Y_1, Y_2, \ldots$ konvergiert in W'keit gegen eine reellwertige Zufallsvariable Y, falls für alle $\varepsilon > 0$ gilt:

$$\lim_{n \to \infty} P\left(|Y_n - Y| > \varepsilon\right) = 0.$$

Die Aussage von Satz 10.3 lässt sich also auch so formulieren: die Mittelwerte $\frac{S_n}{n}$ konvergieren in W'keit gegen den Erwartungswert μ.

Es gibt noch andere naheliegende Methoden, die Konvergenz von Zufallsvariablen zu definieren. Hier ist die Definition der sog. *fast sicheren Konvergenz*:

Definition 10.6. Eine Folge von Zufallsvariablen $Y_1, Y_2, \ldots$ konvergiert fast sicher (f.s.) gegen eine Zufallsvariable Y, falls

$$P\left(\left\{\omega \in \Omega : \lim_{n\to\infty} Y_n(\omega) = Y(\omega)\right\}\right) = 1.$$

Man kann auch folgendes Konvergenzresultat zeigen:

Satz 10.7 (Starkes Gesetz der großen Zahl)**.** *$\frac{1}{n}S_n$ konvergiert fast sicher gegen μ.*

Beweis. Stochastik-VL. □

Was ist Zusammenhang zwischen der Konvergenz in W'keit und f.s. Konvergenz? In der Stochastik-Vorlesung (kommendes Sommersemester) werden wir zeigen: f.s. Konvergenz impliziert Konvergenz in W'keit; aber die umgekehrte Implikation gilt nicht. Dies ist der Grund, weshalb man Satz 10.7 stark, und Satz 10.3 schwach nennt.

Der zentrale Grenzwertsatz

In diesem Abschnitt untersuchen wir

$$Z_n = \frac{S_n - n\mu}{\sqrt{n}\sigma}, \qquad n \geq 1.$$

Beachte:

$$E(Z_n) = \frac{1}{\sqrt{n}\sigma}(E(S_n) - n\mu) = 0,$$

und

$$\mathrm{Stabw}(Z_n) = \frac{1}{\sqrt{n}\sigma}\sqrt{\mathrm{Var}(S_n)} = \frac{1}{\sqrt{n}\sigma}\sqrt{n}\sigma = 1.$$

Man nennt deshalb Z_n *standardisierte Summe* von $X_1, \ldots, X_n$.

Man kann zeigen, dass die Verteilung der standardisierten Summen Z_n gegen die Standardnormalverteilung konvergiert. Es gilt folgender Satz:

Satz 10.8 (Zentraler Grenzwertsatz (ZGS)). *Für alle $a \in [-\infty, \infty)$ und $b \in (-\infty, \infty]$ mit $a \leq b$ gilt*

$$\lim_{n\to\infty} P(a < Z_n \leq b) = \int_a^b \frac{1}{\sqrt{2\pi}} e^{-x^2/2} dx. \tag{10.5}$$

Beweis. Stochastik. □

Bemerkung. a) Ein Grund, warum als Limesverteilung die Standardnormalverteilung erscheint, ist folgende Invarianzeigenschaft: Sind X und Y zwei $\mathcal{N}(0,1)$-verteilte und unabhängige Zufallsvariablen, so ist $\frac{1}{\sqrt{2}}(X+Y)$ ebenfalls $\mathcal{N}(0,1)$-verteilt.

b) Die Aussage (10.5) gilt auch, wenn man auf der linken Seiten $<$ durch $\leq$ ersetzt und/oder $\leq$ durch $<$.

c) Sei F_n die Verteilungsfunktion von Z_n und Φ die Verteilungsfunktion von $\mathcal{N}(0,1)$ (d.h. $\Phi(y) = \int_{-\infty}^{y} \frac{1}{\sqrt{2\pi}} e^{-x^2/2} dx$). Dann lässt sich die Aussage des ZGS wie folgt formulieren:

$$\lim_n F_n(x) = \Phi(x), \qquad \text{für alle } x \in \mathbb{R}.$$

Wir illustrieren jetzt typische Anwendungen des ZGS.

Beispiel 10.9. *Es bezeichne $X_1, \ldots, X_{34}$ die Punkte, die eine Fussballmannschaft in den Spielen einer Bundesliga-Saison erzielt. Es gelte, dass $X_1, \ldots, X_{34}$ i.i.d. ist mit*

$$P(X_i = 0) = P(X_i = 3) = \frac{2}{5} \qquad \textit{und} \qquad P(X_i = 1) = \frac{1}{5}.$$

Hieraus folgt $E(X_i) = 1,4$ und $Var(X_i) = 1,84$. Mit welcher W'keit erzielt die Mannschaft insgesamt höchstens 33 Punkte?

$$\begin{aligned} P(S_{34} \leq 33) &= P\left(\frac{S_{34} - 34 * 1,4}{\sqrt{34}\sqrt{1,84}} \leq \frac{33 - 34 * 1,4}{\sqrt{34}\sqrt{1,84}}\right) \\ &\overset{ZGS}{\approx} \Phi\left(\frac{33 - 34 * 1,4}{\sqrt{34}\sqrt{1,84}}\right) \approx \Phi(-1,84) \\ &= 1 - \Phi(1,84) \\ &\approx 0,034. \qquad\qquad (\textit{siehe Tabelle im Anhang}) \end{aligned}$$

Bemerkung: Am Ende der Bundesligasaison 22/23 hatte die Mannschaft auf dem Relegationsplatz genau 33 Punkte.

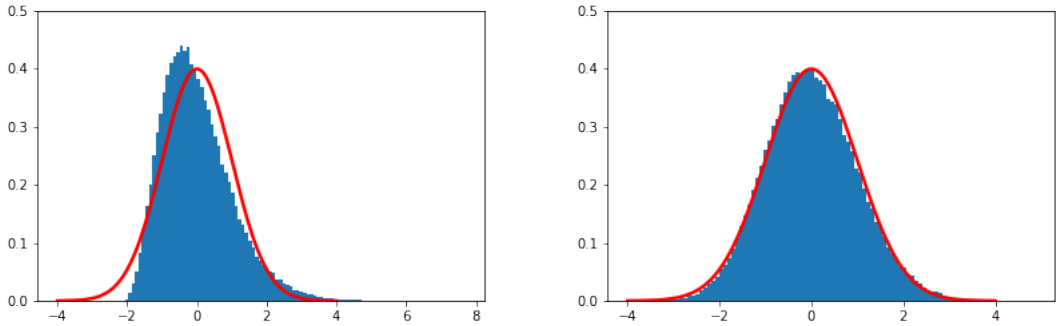

Abbildung 1: Ergebnisse des Experiments mit $n = 5$ (links) und $n = 100$ (rechts).

Beispiel 10.10. *$X_1, \ldots, X_{100}$ seien unabhängige $\mathcal{U}[0,1]$-verteilte Zufallsvariablen. Wir bestimmen näherungsweise $P(\sum_{i=1}^{100} X_i > 51)$ mit Hilfe des ZGS. Beachte: $\mu = E(X_i) = \frac{1}{2}$ und $\sigma^2 = Var(X_i) = \frac{1}{12}$. Somit gilt*

$$\begin{aligned}
P\left(\sum_{i=1}^{100} X_i > 51\right) &= 1 - P\left(\sum_{i=1}^{100} X_i \leq 51\right) \\
&= 1 - P\left(\frac{(\sum_{i=1}^{100} X_i) - 100\mu}{\sqrt{100}\sigma} \leq \frac{51 - 100\mu}{\sqrt{100}\sigma}\right) \\
&\approx 1 - \Phi\left(\frac{51 - 100\mu}{\sqrt{100}\sigma}\right) = 1 - \Phi\left(\frac{\sqrt{12}}{10}\right) \\
&= 1 - \Phi(0,35) \approx 1 - 0,6368 \\
&= 0,3632.
\end{aligned}$$

Wir illustrieren nun die Aussage des ZGS mit folgendem numerischen Experiment:

Wir nehmen zunächst an, dass jedes X_i exponentialverteilt zum Paramter 1 ist. Dann gilt $\mu = 1$ und $\sigma^2 = 1$. Wir ziehen 100000 Mal aus der Verteilung von $\frac{\sum_{i=1}^{n}(X_i - 1)}{\sqrt{n}}$ für $n = 5$ und $n = 100$. Die gezogenen Werte stellen wir in einem Histogramm mit 100 Balken dar. Die Abbildung 1 zeigt das Ergebnis für eine konkrete Ausführung des Experiments an. Beachte: die Balkenhöhe ist so normiert, dass die Fläche des Histogramms 1 ergibt. Die rote Linie stellt den Graphen der Dichte der Standardnormalverteilung dar.

Teil II
Statistik

11 Punktschätzungen

Frage: Wie lässt sich die Verteilung von beobachteten Größen oder Daten bestimmen? Das Bestimmen einer Verteilung (= WM auf $\mathbb{R}$) für eine Menge von Beobachtungen nennt man *statistische Inferenz*.

Häufig kann man die Verteilungen, die in Frage kommen, stark eingrenzen. Beispiele:

a) Anzahl der Treffer in einem Fussball-Spiel ist Poisson-verteilt (wegen Satz 6.8); nur der Parameter λ der Poisson-Verteilung ist unbekannt. Weiteres Poisson-verteiltes Beispiel: Anzahl der Atome in 1 g Uran, die in 1 Stunde zerfallen.

b) Die Zeit zwischen eingehenden Telefonanrufen ist exponential-verteilt, nur der Parameter α ist unbekannt.

c) Die Positionsänderung eines kleinen Partikels in einer Flüssigkeit oder einem Gas ist normalverteilt; Mittelwert ist 0, aber die Varianz ist unbekannt.

d) Messwerte sind annähernd normalverteilt (wegen des ZGS bewirken viele kleine Einflüsse eine insgesamt normalverteilte Streuung um den tatsächlichen Wert); der Mittelwert und die Varianz sind unbekannt.

Wir nehmen im Folgenden an, dass die Menge der in Frage kommenden Verteilungen mit einer Menge $\Theta \subset \mathbb{R}^d$ parametrisiert werden kann. Des Weiteren interpretieren wir die Beobachtungen (auch Stichproben genannt) als Realisierungen von Zufallsvariablen $X_1, \ldots, X_n$ auf einem Wahrscheinlichkeitsraum $(\Omega, \mathcal{A}, P)$, wobei $n \in \mathbb{N}$ die Anzahl der Beobachtungen ist. Wir nehmen an, dass eine Familie $(P_\theta)_{\theta \in \Theta}$ von Wahrscheinlichkeitsmaßen gegeben ist, sodass unter jedem P_θ die Zufallsvariablen unabhängig sind und jedes X_i die Verteilung mit Parameter θ hat.

Notation: Wir bezeichnen mit $E_\theta[X_i]$ den Erwartungswert von X_i unter P_θ, mit $\mathrm{Var}_\theta(X_i)$ die Varianz von X_i unter P_θ, etc. Weiterhin bezeichnen wir die Dichte bzw die Zähldichte unter P_θ mit $f(\cdot|\theta)$. In den Beispielen oben sind die Funktionen $f(\cdot|\theta)$ wie folgt gegeben:

a) $f(k|\theta) = e^{-\theta} \frac{\theta^k}{k!}$, $k \in \mathbb{N}_0$, $\theta \in (0, \infty)$;

b) $f(x|\theta) = \theta e^{-\theta x}$, $x \in [0, \infty)$, $\theta \in (0, \infty)$;

c) $f(x|\theta) = \frac{1}{\sqrt{2\pi\theta}} e^{-\frac{x^2}{2\theta}}$, $x \in \mathbb{R}$, $\theta \in (0, \infty)$;

d) $f(x|(\theta_1, \theta_2)) = \frac{1}{\sqrt{2\pi\theta_2}} e^{-\frac{(x-\theta_1)^2}{2\theta_2}}$, $x \in \mathbb{R}$, $(\theta_1, \theta_2) \in \mathbb{R} \times (0, \infty)$.

Die Familie der Dichten bzw Zähldichten $f(\cdot|\theta)_{\theta \in \Theta}$ nennt man *parametrisches Modell*.

Wie können wir nun aufgrund der Beobachtungen einen Parameter aus Θ auf sinnvolle Art wählen? Wir führen zunächst den Begriff des Punktschätzers ein.

Definition 11.1. Sei $T : \mathbb{R}^n \to \Theta$ eine Abbildung. Dann ist $\hat{T} : \Omega \to \Theta, \omega \mapsto T(X_1(\omega), \ldots, X_n(\omega))$ ein Punktschätzer (kurz: Schätzer) für den Parameter θ mit Schätzfunktion T.

Wie lassen sich gute Schätzer bestimmen? Häufig werden Schätzer konstruiert mit Hilfe der sog. Momentenmethode oder der Maximum-Likelihood-Methode. Wir schauen uns jetzt beide Verfahren näher an.

11.1 Die Momentenmethode

Seien $y_1, \ldots, y_n \in \mathbb{R}$ die beobachteten Werte. Erinnerung: wir interpretieren $y_1, \ldots, y_n$ als Realisierungen der Zufallsvariablen $X_1, \ldots, X_n$.

Betrachte zunächst den Fall, wo der zu bestimmende Parameter θ eindimensional ist (d.h. $\Theta \subset \mathbb{R}$).

Die Momentenschätzfunktion ordnet nun den Beobachtungen das θ zu, für das das empirische Mittel $\frac{1}{n} \sum_{i=1}^n y_i$ mit dem Erwartungswert $E_\theta[X_i]$ übereinstimmt. Wir bezeichnen im Folgenden die Momentenschätzfunktion mi T_{MM} und mit $\widehat{T}_{MM} := T_{MM}(X_1, \ldots, X_n)$ den Momentenschätzer.

Beispiel 11.2. *Sei $f(k|\theta) = e^{-\theta} \frac{\theta^k}{k!}$ die Zähldichte der Poisson-Verteilung mit Parameter $\theta \in (0, \infty)$. Beachte: $E_\theta[X_i] = \theta$ (siehe ÜB 4, Präsenzaufg. 2). Also ist die Momentenschätzfunktion für θ gegeben durch $T_{MM}(y_1, \ldots, y_n) = \frac{1}{n} \sum_{i=1}^n y_i$.*

Beispiel 11.3. *Sei $f(x|\theta) = \theta e^{-\theta x}$ die Dichte der Exponentialverteilung auf $[0, \infty)$ mit $\theta \in (0, \infty)$. Es gilt $E_\theta[X_i] = \frac{1}{\theta}$ (vgl. Aufgabe 3, ÜB 4). Also ist die Momentenschätzfunktion gegeben durch $T_{MM}(y_1, \ldots, y_n) = \frac{1}{\frac{1}{n} \sum_{i=1}^n y_i}$.*

Sei nun $\theta = (\theta_1, \ldots, \theta_d)$ ein d-dimensionaler Vektor. In diesem Fall setzt man die ersten d Momente von X_i mit den entsprechenden empirischen Momenten gleich:

$$\begin{aligned} E_\theta[X_i] &= \frac{1}{n}\sum_{i=1}^n y_i \\ E_\theta[X_i^2] &= \frac{1}{n}\sum_{i=1}^n y_i^2 \\ &\vdots \\ E_\theta[X_i^d] &= \frac{1}{n}\sum_{i=1}^n y_i^d \end{aligned} \tag{11.1}$$

In der Regel existiert genau ein Vektor θ, für den das Gleichungssystem (11.1) erfüllt ist. Die Momentenschätzfunktion ordnet nun den Beobachtungen $y_1, \ldots, y_n$ die Lösung von (11.1) zu.

Beispiel 11.4. *Sei* $f(x|(\theta_1, \theta_2)) = \frac{1}{\sqrt{2\pi\theta_2}} e^{-\frac{(x-\theta_1)^2}{2\theta_2}}$ *die Dichte der Normalverteilung mit Mittelwert* θ_1 *und Varianz* θ_2, $(\theta_1, \theta_2) \in \mathbb{R} \times (0, \infty)$.

Beachte: $E_\theta(X) = \theta_1$ *und* $E_\theta(X^2) = \theta_1^2 + \theta_2$. *Wir müssen also folgendes Gleichungssystem lösen:*

$$\begin{aligned} \theta_1 &= \frac{1}{n}\sum_{i=1}^n y_i \\ \theta_1^2 + \theta_2 &= \frac{1}{n}\sum_{i=1}^n y_i^2 \end{aligned}$$

Wir lösen die zweite Gleichung nach θ_2 *auf und erhalten*

$$\theta_2 = \left(\frac{1}{n}\sum_{i=1}^n y_i^2\right) - \theta_1^2 = \left(\frac{1}{n}\sum_{i=1}^n y_i^2\right) - \left(\frac{1}{n}\sum_{i=1}^n y_i\right)^2 = \frac{1}{n}\sum_{i=1}^n \left(y_i - \frac{1}{n}\sum_{j=1}^n y_j\right)^2.$$

Also ist die Momentenschätzfunktion gegeben durch

$$T_{MM}(y_1, \ldots, y_n) = \begin{pmatrix} \frac{1}{n}\sum_{i=1}^n y_i \\ \frac{1}{n}\sum_{i=1}^n \left(y_i - \frac{1}{n}\sum_{j=1}^n y_j\right)^2 \end{pmatrix}.$$

11.2 Die Maximum-Likelihood-Methode

Sei $(f(\cdot, \theta))_{\theta \in \Theta}$ ein parametrisches Modell.

Wir betrachten zunächst den Fall, wo jedes $f(\cdot,\theta)$ eine Zähldichte ist. Mit anderen Worten: $X_1,\dots,X_n$ sind diskrete Zufallsvariablen unter allen WM P_θ.

Seien $y_1,\dots,y_n \in \mathbb{R}$ gegebene Beobachtungen. Unter P_θ gilt für die Wahrscheinlichkeit dieser Beobachtungen

$$P_\theta(\{X_1 = y_1\} \cap \dots \{X_n = y_n\}) = \prod_{i=1}^n P_\theta(X_i = y_i) = \prod_{i=1}^n f(y_i|\theta).$$

Idee der Maximum-Likelihood-Methode: wähle θ so, dass die Wahrscheinlichkeit maximal wird.

Etwas formaler: Die Abbildung

$$L(\theta) := \prod_{i=1}^n f(y_i|\theta), \qquad \theta \in \Theta, \tag{11.2}$$

heißt Likelihood-Funktion. Wir nehmen im Folgenden an, dass die Likelihood-Funktion ihr Supremum auf Θ annimmt. Eine Abbildung $T_{ML} : \mathbb{R}^n \to \Theta$ heißt Maximum-Likelihood-Schätzfunktion, falls

$$T_{ML}(y_1,\dots,y_n) \in \operatorname{argmax}_{\theta\in\Theta} L(\theta). \tag{11.3}$$

Erinnerung: Sei f eine Funktion, die ihr Supremum annimmt. Dann bezeichnet argmax f die Menge aller Maximalstellen.

Definition 11.5. $\widehat{T}_{ML} := T_{ML}(X_1,\dots,X_n)$ heißt Maximum-Likelihood-Schätzer (kurz: ML-Schätzer) von θ.

Beispiel 11.6. *Sei $\Theta = [0,1]$ und $f(\cdot,\theta)$ die Zähldichte der Bernoulli-Verteilung zum Parameter $\theta \in \Theta$ (d.h. $f(1|\theta) = \theta$ und $f(0|\theta) = 1-\theta$). Für $y_1,\dots,y_n \in \{0,1\}$ ist die Likelihood-Funktion dann gegeben durch*

$$L(\theta) = \theta^{\sum_{i=1}^n y_i}\,(1-\theta)^{n-\sum_{i=1}^n y_i}.$$

Falls $\theta \in (0,1)$ eine Maximalstelle von L, so gilt die BEO: $L'(\theta) = 0$. Setze $a := \sum_{i=1}^n y_i$. Wir unterscheiden 3 Fälle:
1. Fall: $a \in \{1,\dots,n-1\}$. Dann gilt

$$\begin{aligned} L'(\theta) &= \frac{d}{d\theta}\left(\theta^a(1-\theta)^{n-a}\right) = a\theta^{a-1}(1-\theta)^{n-a} - \theta^a(n-a)(1-\theta)^{n-a-1} \\ &= (a(1-\theta) - \theta(n-a))\theta^{a-1}(1-\theta)^{n-a-1}. \end{aligned}$$

Die BEO impliziert

$$(a(1-\theta) - \theta(n-a)) = 0,$$

und weiter

$$\theta = \frac{a}{n}.$$

2. Fall: $a = 0$. *Dann ist* $L(\theta) = (1-\theta)^n$ *und* $\theta = 0$ *Maximalstelle.*
3. Fall: $a = n$. *Dann ist* $L(\theta) = \theta^n$ *und* $\theta = 1$ *Maximalstelle.*

Insgesamt erhalten wir, dass die Funktion L *ihr Maximum bei* $\theta = \frac{a}{n}$ *annimmt. Also ist die ML-Schätzfunktion für* θ *gegeben durch* $T_{ML} = \frac{1}{n}\sum_{i=1}^n y_i$.

Beachte: die Momentenschätzfunktion stimmt in diesem Beispiel mit der ML-Schätzfunktion überein.

Wir betrachten nun den absolutstetigen Fall. Dazu beachte, dass die Definition (11.2) auch sinnvoll ist, falls $f(\cdot|\theta)$ eine Dichte einer absolutstetigen ZV ist. Wie im diskreten Fall definieren wir auch hier T_{ML} wie in (11.3), und $\widehat{T}_{ML}$ wie in Definition 11.5.

Beispiel 11.7 (Fortsetzung von Bsp 11.4)**.** *Sei* $f(x|(\theta_1,\theta_2)) = \frac{1}{\sqrt{2\pi\theta_2}} e^{-\frac{(x-\theta_1)^2}{2\theta_2}}$ *die Dichte der Normalverteilung mit Mittelwert* θ_1 *und Varianz* θ_2, $(\theta_1,\theta_2) \in \mathbb{R} \times (0,\infty)$.

Wir bestimmen nun den ML-Schätzer für θ. *Zunächst beachte, dass* L *an der selben Stelle ihr Maximum annimmt, wie die logarithmierte Funktion* $\ln(L)$ *(auch Log-Likelihood-Funktion genannt) und*

$$\begin{aligned}\ln(L(\theta)) &= \sum_{i=1}^n \left(\ln(\frac{1}{\sqrt{2\pi\theta_2}}) - \frac{(y_i-\theta_1)^2}{2\theta_2} \right) \\ &= -\frac{n}{2}\ln(2\pi) - \frac{n}{2}\ln(\theta_2) - \frac{1}{2\theta_2}\sum_{i=1}^n (y_i-\theta_1)^2. \qquad (11.4)\end{aligned}$$

BEO für θ_1*:*

$$\frac{d}{d\theta_1}\left[\ln(L(\theta))\right] = \frac{1}{\theta_2}\sum_{i=1}^n (y_i-\theta_1) = 0.$$

Dies lässt sich vereinfachen zu

$$n\theta_1 = \sum_{i=1}^n y_i. \qquad (11.5)$$

BEO für θ_2*:*

$$\frac{d}{d\theta_2}(\ln(L(\theta)) = -\frac{n}{2\theta_2} + \frac{1}{2\theta_2^2}\sum_{i=1}^n (y_i-\theta_1)^2 = 0.$$

Hieraus folgt

$$\frac{1}{\theta_2}\sum_{i=1}^{n}(y_i-\theta_1)^2=\frac{n}{2}. \tag{11.6}$$

Durch Lösen von (11.5) *und* (11.6) *erhalten wir*

$$T_{ML}(y_1,\ldots,y_n)=\begin{pmatrix} \frac{1}{n}\sum_{i=1}^{n} y_i \\ \frac{1}{n}\sum_{i=1}^{n}\left(y_i-\frac{1}{n}\sum_{j=1}^{n} y_j\right)^2 \end{pmatrix}.$$

In den bisherigen Beispielen stimmen die ML-Schätzer und die Momentenschätzer überein. Das muss nicht immer so sein, wie folgendes Beispiel zeigt.

Beispiel 11.8. *Sei* $f(x|\theta)=\frac{1}{\theta}1_{[0,\theta]}(x)$, $x\in\mathbb{R}$ *und* $\theta\in(0,\infty)$.

Der Erwartungswert einer Zufallsvariablen mit Dichte $f(\cdot|\theta)$ *ist* $\frac{\theta}{2}$. *Also gilt* $T_{MM}(y_1,\ldots,y_n)=\frac{2}{n}\sum_{i=1}^{n} y_i$.

Um den ML-Schätzer zu bestimmen, halten wir zunächst fest:

$$L(\theta)=\prod_{i=1}^{n}\frac{1}{\theta}1_{[0,\theta]}(y_i)=\begin{cases} \frac{1}{\theta^n}, & \textit{falls } \max\{y_1,\ldots,y_n\}\le\theta, \\ 0, & \textit{falls } \max\{y_1,\ldots,y_n\}>\theta. \end{cases}$$

$L(\theta)$ *wird maximal an der Stelle* $\max\{y_1,\ldots,y_n\}$. *Somit gilt*

$$T_{ML}(y_1,\ldots,y_n)=\max\{y_1,\ldots,y_n\}.$$

Beachte: i.A. gilt $T_{MM}\neq T_{ML}$ *(zB für* $n=1$ *und* $y_1>0$*).*

11.3 Bias und mittlerer quadratischer Fehler

Es gibt verschiedene Methoden, die Güte von Schätzern zu untersuchen. Ein bekanntes Gütekriterium ist der sogenannte Bias.

Definition 11.9. Sei $\hat{T}=T(X_1,\ldots,X_n)$ ein Schätzer mit Werten in $\Theta\subset\mathbb{R}^d$ und $i\in\{1,\ldots,d\}$. Wir bezeichnen mit θ_i die i-te Komponente von θ und mit $\hat{T}_i$ die i-te Komponente von $\hat{T}$. Der *Bias* von $\hat{T}_i$ ist definiert durch

$$\mathcal{B}_\theta(\hat{T}_i)=E_\theta[\hat{T}_i]-\theta_i.$$

Ist der Bias von $\hat{T}_i$ für alle $\theta\in\Theta$ gleich null, so nennt man $\hat{T}_i$ *erwartungstreu.*

Bemerkung. Im Allgemeinen gilt: Je kleiner der Betrag des Bias, desto besser. Beachte: $\hat{T}_i$ ist erwartungstreu gdw für alle $\theta\in\Theta$ gilt:

$$E_\theta[\hat{T}_i]=\theta_i.$$

Beispiel 11.10 (Fortsetzung von Bsp 11.4 und 11.7)**.** *Sei* $f(x|(\theta_1,\theta_2)) = \frac{1}{\sqrt{2\pi\theta_2}}e^{-\frac{(x-\theta_1)^2}{2\theta_2}}$ *mit* $(\theta_1,\theta_2) \in \mathbb{R}\times(0,\infty)$*. Wir haben bereits gezeigt, dass*

$$T_{MM}(y_1,\ldots,y_n) = T_{ML}(y_1,\ldots,y_n) = \begin{pmatrix} \frac{1}{n}\sum_{i=1}^n y_i \\ \frac{1}{n}\sum_{i=1}^n \left(y_i - \frac{1}{n}\sum_{j=1}^n y_j\right)^2 \end{pmatrix}.$$

Setze $\widehat{T} := T_{MM}(X_1,\ldots,X_n)$*. Dann gilt*

a) $\hat{T}_1 = T_1(X_1,\ldots,X_n)$ *ist ein erwartungstreuer Schätzer für* θ_1*;*

b) $\hat{T}_2 = T_2(X_1,\ldots,X_n)$ *ist* ***kein*** *erwartungstreuer Schätzer für* θ_2*.*

Beweis von a):

$$E_\theta[\hat{T}_1] = E_\theta\left[\frac{1}{n}\sum_{i=1}^n X_i\right] = \frac{1}{n}\sum_{i=1}^n E_\theta[X_i] = \frac{1}{n}n\theta_1 = \theta_1.$$

Beweis von b):

$$\begin{aligned}
E_\theta[\hat{T}_2] &= \frac{1}{n}E_\theta\left[\sum_{i=1}^n (X_i - \frac{1}{n}\sum_{j=1}^n X_j)^2\right] \\
&= \frac{1}{n}\sum_{i=1}^n E_\theta[(X_i - \theta_1 + \theta_1 - \frac{1}{n}\sum_{j=1}^n X_j)^2] \\
&= \frac{1}{n}\sum_{i=1}^n E_\theta\left[\left((X_i-\theta_1) - \frac{1}{n}\sum_{j=1}^n (X_j-\theta_1)\right)^2\right] \\
&= \frac{1}{n}\sum_{i=1}^n \left\{E_\theta[(X_i-\theta_1)^2] - 2E_\theta[(X_i-\theta_1)\frac{1}{n}\sum_{j=1}^n (X_j-\theta_1)] + \frac{1}{n^2}Var_\theta\left(\sum_{j=1}^n X_j\right)\right\} \\
&= \frac{1}{n}\sum_{i=1}^n \left\{\theta_2 - \frac{2}{n}E_\theta[(X_i-\theta_1)^2] + \frac{1}{n^2}\sum_{j=1}^n Var_\theta(X_j)\right\} \\
&= \frac{1}{n}\sum_{i=1}^n \left\{\theta_2 - \frac{2}{n}\theta_2 + \frac{1}{n^2}n\theta_2\right\} \\
&= \frac{1}{n}n\theta_2\{1-\frac{1}{n}\} \\
&= \frac{n-1}{n}\theta_2 \neq \theta_2.
\end{aligned}$$

Satz 11.11. *Sei $f(x|(\theta_1,\theta_2))$ ein parametrisches Modell mit $E_\theta(X_i) = \theta_1$ und $Var_\theta(X_i) = \theta_2$, wobei $(\theta_1,\theta_2) \in \mathbb{R} \times (0,\infty)$. Dann sind*

$$\hat{T}_1 = \frac{1}{n}\sum_{i=1}^n X_i,$$
$$\hat{T}_2 = \frac{1}{n-1}\sum_{i=1}^n \left(X_i - \frac{1}{n}\sum_{j=1}^n X_j\right)^2$$

erwartungstreue Schätzer für θ_1 bzw θ_2.

Beweis. Eine Berechnung ähnlich wie im Beweis von b) im Bsp 11.10 zeigt, dass die Schätzer erwartungstreu sind. □

Beispiel 11.12 (Fortsetzung von Bsp. 11.8)**.** *Sei $f(x|\theta) = \frac{1}{\theta}1_{[0,\theta]}(x)$, $x \in \mathbb{R}$ und $\theta \in (0,\infty)$.*

Der Momentenschätzer $\hat{T}_{MM} = \frac{2}{n}\sum_{i=1}^n X_i$ ist erwartungstreu (dies folgt direkt aus der Definition). Der ML-Schätzer $\hat{T}_{ML} = \max\{X_1,\dots,X_n\}$ i.A. aber nicht. Um dies zu zeigen, bestimmen wir zunächst die Verteilungsfunktion F_θ von $\hat{T}_{ML}$ unter P_θ. Für $x \in [0,\theta]$ gilt

$$\begin{aligned} F_\theta(x) &= P(\max\{X_1,\dots,X_n\} \le x) \\ &= P\left(\{X_1 \le x\} \cap \cdots \{X_n \le x\}\right) \\ &= \prod_{i=1}^n P(X_i \le x) \\ &= \frac{x^n}{\theta^n}. \end{aligned}$$

Also hat $\hat{T}_{ML}$ die Dichte $f_\theta(x) = \frac{nx^{n-1}}{\theta^n}1_{[0,\theta]}(x)$ unter P_θ. Somit gilt

$$E_\theta[\hat{T}_{ML}] = \int_0^\theta x\frac{nx^{n-1}}{\theta^n}dx = \frac{n}{\theta^n}\int_0^\theta x^n dx = \frac{n}{\theta^n}\left(\frac{x^{n+1}}{n+1}\Big|\right)_0^\theta = \frac{n}{n+1}\theta.$$

Der Bias von $\hat{T}_{ML}$ ist somit

$$\mathcal{B}_\theta(\hat{T}_{ML}) = E_\theta[\hat{T}_{ML}] - \theta = -\frac{1}{n+1}\theta.$$

Beachte: der Bias ist negativ, konvergiert aber gegen 0 mit $n \to \infty$.

Definition 11.13. Sei $\hat{T}$ ein Schätzer für einen Parameter $\theta \in \Theta \subset \mathbb{R}$. Der mittlere quadratische Fehler ist definiert durch

$$\mathrm{MSE}_\theta(\hat{T}) := E_\theta[(\hat{T} - \theta)^2].$$

Lemma 11.14. *Es gilt*

$$MSE_\theta(\hat{T}) = Var_\theta(\hat{T}) + \mathcal{B}_\theta(\hat{T})^2.$$

Beweis.

$$\begin{aligned}
\mathrm{MSE}_\theta(\hat{T}) &= E_\theta[(\hat{T} - E_\theta(\hat{T}) + E_\theta(\hat{T}) - \theta)^2] \\
&= E_\theta[(\hat{T} - E_\theta(\hat{T}))^2] - 2E_\theta[(\hat{T} - E_\theta(\hat{T}))(E_\theta(\hat{T}) - \theta)] + (E_\theta(\hat{T}) - \theta)^2 \\
&= E_\theta[(\hat{T} - E_\theta(\hat{T}))^2] + (E_\theta(\hat{T}) - \theta)^2 \\
&= \mathrm{Var}_\theta(\hat{T}) + \mathcal{B}_\theta(\hat{T})^2.
\end{aligned}$$

□

Beispiel 11.15 (Fortsetzung von Bsp. 11.8 und 11.12)**.** *Sei* $f(x|\theta) = \frac{1}{\theta}1_{[0,\theta]}(x)$, $x \in \mathbb{R}$ *und* $\theta \in (0, \infty)$.

Für den mittleren quadratischen Fehler des Momentenschätzers $\hat{T}_{MM}$ *gilt*

$$\begin{aligned}
MSE_\theta(\hat{T}_{MM}) = Var_\theta(\hat{T}_{MM}) &= Var_\theta(\frac{2}{n}\sum_{i=1}^n X_i) \\
&= \frac{4}{n^2}\sum_{i=1}^n Var_\theta(X_i) \\
&= \frac{4}{n^2} n \int_0^\theta \frac{1}{\theta}(x - \theta/2)^2 dx \\
&= \frac{4}{n}\frac{\theta^2}{12} \\
&= \frac{\theta^2}{3n},
\end{aligned}$$

Erinnerung: die Dichte des ML-Schätzers $\hat{T}_{ML}$ *ist* $f_\theta(x) = n\frac{x^{n-1}}{\theta^n}1_{[0,\theta]}(x)$. *Also gilt für den mittleren quadratischen Fehler*

$$\begin{aligned}
MSE_\theta(\hat{T}_{ML}) &= \int_0^\theta (x-\theta)^2 n \frac{x^{n-1}}{\theta^n} dx \\
&= \frac{n}{\theta^n}\int_0^\theta x^{n+1} dx - \frac{2n}{\theta^{n-1}}\int_0^\theta x^n dx + \theta^2 \\
&= \frac{n}{\theta^n}\frac{\theta^{n+2}}{n+2} - \frac{2n}{\theta^{n-1}}\frac{\theta^{n+1}}{n+1} + \theta^2 \\
&= \left(\frac{n}{n+2} - \frac{2n}{n+1} + 1\right)\theta^2 \\
&= \frac{2\theta^2}{(n+1)(n+2)}.
\end{aligned}$$

Beachte: Für $n \to \infty$ konvergiert der MSE von $\hat{T}_{ML}$ schneller gegen 0 als der MSE von $\hat{T}_{MM}$.

Bemerkung: auf ÜB 6 (?) werden wir einen weiteren Schätzer für θ kennenlernen. Dieser hat sogar einen noch kleineren MSE als $\hat{T}_{ML}$.

11.4 Punkt- versus Bereichsschätzer

Manchmal ist man nicht an den genauen Wert des Parameters einer Verteilung interessiert, sondern nur an den Bereich, in dem sich dieser mit hoher Wahrscheinlichkeit befindet. Eine Abbildung, die den Beobachtungen eine Teilmenge von Θ zuordnet, nennt man Bereichsschätzer. Besonders relevante Bereichsschätzer sind die sog. Konfidenzintervalle.

Definition 11.16. Sei $\Theta \subset \mathbb{R}$ und $f(\cdot|\theta)$ ein parametrisches Modell. Sei $\alpha \in (0,1)$ und $u : \mathbb{R}^n \to \Theta$ und $d : \mathbb{R}^n \to \Theta$ zwei Funktionen. Das stochastische Intervall $[d(X_1, \ldots, X_n), u(X_1, \ldots, X_n)]$ heißt Konfidenzintervall für θ zum Irrtumsniveau α, falls für alle $\theta \in \Theta$ gilt:

$$P_\theta(d(X_1, \ldots, X_n) \leq \theta \leq u(X_1, \ldots, X_n)) \geq 1 - \alpha. \tag{11.7}$$

Bemerkung. a) Die Funktionen u und d, für die (11.7) gilt, sind nicht eindeutig. Man versucht sie so zu bestimmen, dass die Länge des Konfidenzintervalls möglichst klein ist.
b) (11.7) ist wie folgt zu interpretieren: In mind. $(1 - \alpha) * 100\%$ der Anwendungen des Schätzverfahrens, enthält $[d(X_1, \ldots, X_n), u(X_1, \ldots, X_n)]$ den wahren Wert θ.

Es gibt verschiedene Methoden, Konfidenzintervalle zu bestimmen. Wir illustrieren die Methoden an Hand der Bernoulli-Verteilung.

Konfidenzintervalle für Bernoulli-verteilte Beobachtungen

Wir nehmen im Folgenden an, dass die Beobachtungen $X_1, \ldots, X_n$ Bernoulli-verteilt zum einem unbekannten Parameter $\theta \in [0,1]$ sind. Wir wissen bereits aus Beispiel 11.6, dass der ML-Schätzer für θ gegeben ist durch

$$\hat{T} := \hat{T}_{ML} := \frac{1}{n} \sum_{i=1}^{n} X_i.$$

Wir werden nun verschiedene Methoden zur Konstruktion von Konfidenzintervallen für θ kennenlernen. Dazu sei $\alpha \in (0,1)$ ein festes Irrtumsniveau.

1. Methode: Anwendung der Chebyshev-Ungleichung

Wir suchen ein $\delta \in (0, \infty)$, sodass für alle $\theta \in [0, 1]$

$$P_\theta \left(|\hat{T} - \theta| > \delta \right) \leq \alpha.$$

Beachte: $\{|\hat{T} - \theta| > \delta\} = \{|\hat{T} - \theta|^2 > \delta^2\}$. Aus der Chebyshev-Ungleichung folgt

$$\begin{aligned} P_\theta \left(|\hat{T} - \theta| > \delta \right) &= P_\theta \left(|\hat{T} - \theta|^2 > \delta^2 \right) \\ &\leq \frac{E_\theta(|\hat{T} - \theta|^2)}{\delta^2} = \frac{\mathrm{Var}_\theta(\frac{1}{n} \sum_{i=1}^n X_i)}{\delta^2} \\ &= \frac{1}{n^2} \frac{n \mathrm{Var}_\theta(X_i)}{\delta^2} \\ &= \frac{\theta(1-\theta)}{n\delta^2}. \end{aligned}$$

Die Funktion $[0, 1] \ni \theta \mapsto \theta(1 - \theta)$ nimmt ihr Maximum bei $\theta = \frac{1}{2}$ an. Somit erhalten wir

$$P_\theta \left(|\hat{T} - \theta| > \delta \right) \leq \frac{1}{4n\delta^2}.$$

Beachte: $\frac{1}{4n\delta^2} = \alpha$ genau dann, wenn $\delta = \frac{1}{2\sqrt{n\alpha}}$. Ein Konfidenzintervall zum Irrtumsniveau α ist also gegeben durch

$$I_1 := \left[\hat{T} - \frac{1}{2\sqrt{n\alpha}}, \hat{T} + \frac{1}{2\sqrt{n\alpha}} \right].$$

2. Methode: Anwendung der Hoeffding-Ungleichung

Lemma 11.17 (Hoeffding-Ungleichung)**.** *Sei $Y_1, \ldots, Y_n$ eine Familie von unabhängigen Zufallsvariablen und es gebe $a_1, \ldots, a_n, b_1, \ldots, b_n \in \mathbb{R}$ mit $P(Y_i \in [a_i, b_i]) = 1$, für alle $1 \leq i \leq n$. Dann gilt für alle $t \in (0, \infty)$*

$$P \left(\left| \sum_{i=1}^n Y_i - E(\sum_{i=1}^n Y_i) \right| \geq t \right) \leq 2 \exp \left(- \frac{2t^2}{\sum_{i=1}^n (b_i - a_i)} \right).$$

Wir wenden die Hoeffding-Ungleichung an, um ein Konfidenzintervall für den Bernoulli-Parameter θ zu bestimmen. Zunächst beachte $\{|\hat{T} - \theta| \geq t\} = \{|\sum_{i=1}^n X_i - n\theta| \geq nt\}$. Mit der Hoeffding-Ungleichung folgt

$$P_\theta \left(|\hat{T} - \theta| \geq t \right) = P_\theta \left(|\sum_{i=1}^n X_i - n\theta| \geq nt \right) \leq 2e^{-\frac{2(nt)^2}{n}} = 2e^{-2nt^2}.$$

Beachte: $2e^{-2nt^2} = \alpha$ genau dann, wenn $t = \sqrt{\frac{1}{2n}\ln\left(\frac{2}{\alpha}\right)}$. Somit ist ein Konfidenzintervall zum Irrtumsniveau α gegeben durch

$$I_2 := \left[\hat{T} - \sqrt{\frac{1}{2n}\ln\left(\frac{2}{\alpha}\right)}, \hat{T} + \sqrt{\frac{1}{2n}\ln\left(\frac{2}{\alpha}\right)}\right].$$

Bemerkung: für kleine α ist I_2 kleiner als I_1.

3. Methode: Anwendung der Normalapproximation

Erinnerung: $\sum_{i=1}^n X_i$ ist $\mathcal{B}(N,\theta)$-verteilt unter P_θ. Nach dem ZGS ist für große n

$$\frac{\hat{T}-\theta}{\sqrt{\frac{\theta(1-\theta)}{n}}} = \frac{\sum_{i=1}^n (X_i - \theta))}{\sqrt{n\theta(1-\theta)}}$$

annähernd $\mathcal{N}(0,1)$-verteilt. Folglich gilt für alle $\delta > 0$

$$\begin{aligned}
&P_\theta\left(|\hat{T}-\theta| > \delta\right)\\
&= P_\theta\left(\left|\frac{\hat{T}-\theta}{\sqrt{\frac{\theta(1-\theta)}{n}}}\right| > \delta\sqrt{\frac{n}{\theta(1-\theta)}}\right)\\
&= P_\theta\left(\frac{\hat{T}-\theta}{\sqrt{\frac{\theta(1-\theta)}{n}}} > \delta\sqrt{\frac{n}{\theta(1-\theta)}}\right) + P_\theta\left(\frac{\hat{T}-\theta}{\sqrt{\frac{\theta(1-\theta)}{n}}} < -\delta\sqrt{\frac{n}{\theta(1-\theta)}}\right)\\
&\overset{ZGS}{\approx} 1 - \Phi\left(\delta\sqrt{\frac{n}{\theta(1-\theta)}}\right) + \Phi\left(-\delta\sqrt{\frac{n}{\theta(1-\theta)}}\right)\\
&= 2 - 2\Phi\left(\delta\sqrt{\frac{n}{\theta(1-\theta)}}\right).
\end{aligned}$$

Beachte nun: $2 - 2\Phi\left(\delta\sqrt{\frac{n}{\theta(1-\theta)}}\right) = \alpha$ genau dann, wenn

$$\delta = \sqrt{\frac{\theta(1-\theta)}{n}}\Phi^{-1}(1-\frac{\alpha}{2}). \tag{11.8}$$

Da $\theta(1-\theta) \leq \frac{1}{4}$, ist ein approximatives Konfidenzintervall zum Irrtumsniveau α gegeben durch

$$I_3 := \left[\hat{T} - \frac{1}{2\sqrt{n}}\Phi^{-1}(1-\frac{\alpha}{2}), \hat{T} + \frac{1}{2\sqrt{n}}\Phi^{-1}(1-\frac{\alpha}{2})\right].$$

Alternative: ersetzt man in (11.8) das θ durch $\hat{T}$, so erhält man das sog. Wald-Intervall

$$I_4 := \left[\hat{T} - \sqrt{\frac{\hat{T}(1-\hat{T})}{n}}\Phi^{-1}(1-\frac{\alpha}{2}), \hat{T} + \sqrt{\frac{\hat{T}(1-\hat{T})}{n}}\Phi^{-1}(1-\frac{\alpha}{2})\right].$$

4. Methode: Verwendung der Binomial-Quantile

Erinnerung: $\mathcal{B}(n,\theta;k) = \binom{n}{k}\theta^k(1-\theta)^{n-k}$.

Setze für alle $\theta \in [0,1]$

$$k_-(\theta) := \min\left\{m \in \mathbb{N}_0 : \sum_{k=0}^{m} \mathcal{B}(n,\theta;k) > \frac{\alpha}{2}\right\},$$
$$k_+(\theta) := \max\left\{m \in \mathbb{N}_0 : \sum_{k=m}^{n} \mathcal{B}(n,\theta;k) > \frac{\alpha}{2}\right\},$$

und $C(k) := \{\theta : k \in [k_-(\theta), k_+(\theta)]\}$. Man kann zeigen: $C(k)$ ist Intervall für alle $k \in \{0,1,\ldots,n\}$. Es bezeichne $l(k)$ den linken Rand und $r(k)$ den rechten Rand von $C(k)$. Dann ist

$$I_5 := \left[l\left(\sum_{i=1}^{n} X_i\right), r\left(\sum_{i=1}^{n} X_i\right)\right]$$

ein Konfidenzintervall zum Irrtumsniveau α.

Begründung: Beachte zunächst

$$\{\theta \in I_5\} = \left\{\theta \in C\left(\sum_{i=1}^{n} X_i\right)\right\} = \left\{\sum_{i=1}^{n} X_i \in [k_-(\theta), k_+(\theta)]\right\}.$$

Somit gilt

$$\begin{aligned} P_\theta(\theta \notin I_5) &= P_\theta\left(\sum_{i=1}^{n} X_i < k_-(\theta)\right) + P_\theta\left(\sum_{i=1}^{n} X_i > k_+(\theta)\right) \\ &= \sum_{k=0}^{k_-(\theta)-1} \mathcal{B}(n,\theta;k) + \sum_{k=k_+(\theta)+1}^{n} \mathcal{B}(n,\theta;k) \\ &\leq \frac{\alpha}{2} + \frac{\alpha}{2} = \alpha. \end{aligned}$$

12 Hypothesentests

12.1 Einführende Beispiele

Beispiel 1

Aus der Abitur-Prüfung im Leistungsfach Mathematik im Jahr 2005 in Thüringen (Aufgabe B2 b):

Die Firma Dreh *liefert Schrauben in Packungen zu 1000 Stück in zwei Qualitäten. Bei Packungen 1. Wahl sind 5% Ausschuss, bei 2. Wahl 10% Ausschuss enthalten. Von einer Packung ist die Beschriftung verloren gegangen. Durch einen Test soll die Qualität der Packung festgestellt werden. Dabei soll die Wahrscheinlichkeit, dass eine Packung 2. Wahl als 1. Wahl eingestuft wird, höchstens 0,1 betragen. Planen und erläutern Sie einen entsprechenden Test mit einem Stichprobenumfang von 50! Wie groß wäre in diesem Fall die Wahrscheinlichkeit, dass eine Packung 1. Wahl als 2. Wahl eingestuft wird?*

Wie löst man diese Aufgabe?

Um die Aufgabe zu lösen, stellen wir folgendes Modell auf: Seien $X_1, \ldots, X_{50}$ Zufallsvariablen, die unter P_θ, $\theta \in \{0.05, 0.1\}$, unabhängig und Bernoulliverteilt zum Parameter θ sind. Interpretation:

$X_i = 1$ bedeutet: i-te untersuchte Schraube ist Ausschuss

$X_i = 0$ bedeutet: i-te untersuchte Schraube ist kein Ausschuss

Beachte: Die Anzahl der ermittelten Ausschuss-Schrauben ist gegeben durch $\sum_{i=1}^{50} X_i$.

Wir stellen nun eine Hypthese auf (die sog. Nullhypthese):

$$H_0 : \ \theta = 0.1 \qquad \text{(Packung ist 2. Wahl)}$$

Idee: Wir lehnen H_0 ab, nur falls $\sum_{i=1}^{50} X_i$ kleiner als ein bestimmtes $k \in \mathbb{N}_0$ ist; wobei wir k so wählen, dass

$$P_{0.1}\left(\sum_{i=1}^{50} X_i < k\right) \leq 0,1. \tag{12.1}$$

Für die linke Seite von (12.1) gilt

$$P_{0.1}\left(\sum_{i=1}^{50} X_i < k\right) = \sum_{j=0}^{k-1} P_{0.1}\left(\sum_{i=1}^{50} X_i = j\right) = \sum_{j=0}^{k-1} \mathcal{B}(50, 0.1; j).$$

Aus der Tabelle im Appendix B kann man nun ablesen: $k = 2$ ist die größte natürliche Zahl, für die (12.1) gilt. Somit erhalten wir folgenden

Test: Ist mehr als eine der 50 untersuchten Schrauben Ausschuss, so wird die Packung als 2. Wahl eingestuft. Andernfalls wird sie als 1. Wahl eingestuft.

Bemerkung: der Test ist so konstruiert, dass eine Packung 2. Wahl höchsten mit einer W'keit von 0.1 als 1. Wahl eingestuft wird.

Nun zum zweiten Teil der Aufgabe. Die Wahrscheinlichkeit, dass eine Packung 1. Wahl als 2. Wahl eingestuft wird, beträgt

$$\begin{aligned} P_{0.05}\left(\sum_{i=1}^{50} X_i \geq 2\right) &= 1 - P_{0.05}\left(\sum_{i=1}^{50} X_i \leq 1\right) \\ &\approx 1 - 0,27943 \\ &= 0,72057. \end{aligned}$$

Beispiel 2

Aus der Abitur-Prüfung in Mathematik im Jahr 2010 in Bayern (Aufgabe LM III 3.):

Durch eine Befragung soll der Anteil p der Pkw-Halter abgeschätzt werden, die bereit wären, ein Elektroauto zu kaufen, wenn dies vom Staat mit 2500 Euro bezuschusst wird. Dazu werden 1000 *zufällig ausgewählte Pkw-Halter befragt. Wer mit 'Ja' antwortet, wird als Elektroautokäufer (kurz: EAK) bezeichnet.* [..]

Der Finanzminister vertritt die Hypothese, dass der Anteil p höchstens 20% beträgt. Kann seine Hypothese bei einem Umfrageergebnis von 220 EAK auf einem Signifikanzniveau von 5% abgelehnt werden? Verwenden Sie die Normalverteilung als Näherung.

Wie löst man die Aufgabe?

Wir stellen folgendes Modell auf: Seien $X_1, \ldots, X_{1000}$ Zufallsvariablen, die unter P_θ, $\theta \in [0, 1]$, unabhängig und Bernoulli-verteilt zum Parameter θ sind. Interpretation:

$$\begin{aligned} X_i &= 1 \text{ bedeutet: i-te befragte Person ist EAK} \\ X_i &= 0 \text{ bedeutet: i-te befragte Person ist kein EAK} \end{aligned}$$

Die Hypothese des Finanzministers ist

$$H_0: \ \theta \in [0, 0.2] \qquad \text{(höchstens 20\% sind EAK)}$$

Die zu beantwortende Frage kann nun so umformuliert werden: Gilt unter allen $\theta \in [0, 0.2]$

$$P_\theta \left(\sum_{i=1}^{1000} X_i \geq 220 \right) \leq 0,05? \tag{12.2}$$

Beachte: die Wahrscheinlichkeit auf der LS von (12.2) wird maximal für $\theta = 0,2$. Also genügt es, die Wahrscheinlichkeit nur für $\theta = 0,2$ zu bestimmen. In der Angabe steht, dass man die Normalverteilung als Näherung verwenden soll. Dazu standardisieren wir die Summe $\sum_{i=1}^{1000} X_i$ und verwenden, dass nach dem ZGS deren Verteilung annähernd mit der Standardnormalverteilung übereinstimmt. Wir erhalten

$$\begin{aligned} P_{0,2} \left(\sum_{i=1}^{1000} X_i \geq 220 \right) &= P_{0,2} \left(\frac{\sum_{i=1}^{1000} X_i - 1000 * 0,2}{\sqrt{1000 * 0,2 * 0,8}} \geq \frac{220 - 1000 * 0,2}{\sqrt{1000 * 0,2 * 0,8}} \right) \\ &\approx 1 - \Phi \left(\frac{20}{4\sqrt{10}} \right) \\ &\approx 1 - \Phi\,(1,58) \\ &\approx 0,06. \end{aligned}$$

Also kann die Hypothese des Finanzministers nicht abgelehnt werden auf einem Signifikanzniveau von 5%:

12.2 Hypothesentests für Bernoulli-Verteilungen

Wir beschreiben nun die allgemeine Struktur eines statistischen Hypothesentests. Wir nehmen hierbei an, dass die Beobachtungen $X_1, \ldots, X_n$ Bernoulliverteilt zum einem unbekannten Parameter $\theta \in [0, 1]$ sind. Wir bezeichnen die Summe der Erfolge mit

$$S := S_n := \sum_{i=1}^{n} X_i.$$

Beachte: S ist binomialverteilt zu den Parametern n und θ, wobei letzterer unbekannt ist. S nimmt Werte in $\mathcal{X} := \{0, 1, \ldots, n\}$ an.

Bei einem Hypothesentest will man sich für eine von zwei Hypothesen über den wahren Parameter θ entscheiden. Die Hypothesen werden formuliert mit Hilfe von Mengen Θ_0 und $\Theta_1 \subset [0, 1]$ mit $\Theta_0 \cap \Theta_1 = \emptyset$. Die Nullhypothese lautet:

$$H_0 : \theta \in \Theta_0,$$

und die Alternativhypothese

$$H_1 : \theta \in \Theta_1.$$

Unter einer Testfunktion versteht man eine Abbildung $\varphi : \mathcal{X} \to \{0, 1\}$. Wendet man φ auf S an, so erhält man einen Test. Interpretation:

$\varphi(S) = 0$ bedeutet: an H_0 wird festgehalten; H_1 nicht akzeptiert.

$\varphi(S) = 1$ bedeutet: H_0 wird verworfen, und H_1 akzeptiert.

Bei einem Hypothesentest ist üblicherweise die Wahrscheinlichkeit $\alpha \in [0, 1]$ vorgegeben, mit der man höchstens die Nullhypothese fälschlicherweise verwerfen darf. Ein Test $\varphi(S)$ erfüllt diese Bedingung, falls $\sup_{\theta \in \Theta_0} P_\theta(\varphi(S) = 1) \leq \alpha$. Man sagt dann, dass φ eine Testfunktion zum Niveau α ist.

Bemerkung. a) Welche Hypothese verwendet man als Nullhypothese, und welche als Alternativhypothese? Man verwendet die Hypothese als Nullhypothese, die man fälschlicherweise verwerfen darf höchstens mit der vorgegebenen Irrtumswahrscheinlichkeit α. Häufig handelt es sich um die Hypothese, die man aus Sicht des Testenden möglichst nicht fälschlicherweise ablehnen sollte. In dem Beispiel 1 aus Kapitel 12.1: Es ist nicht so schlimm, eine Packung 1. Wahl als 2. Wahl zu verkaufen, als umgekehrt, eine Packung 2. Wahl als 1. Wahl.

b) Entscheidet man sich für H_1, obwohl H_0 richtig ist, so liegt ein Fehler 1. Art vor. Entscheidet man sich für H_0, obwohl H_1 richtig ist, so liegt ein Fehler 2. Art vor. Beachte: die vorgegebene Irrtumswahrscheinlichkeit α ist eine Schranke an den Fehler 1. Art.

Lemma 12.1. *Sei φ eine Testfunktion. Dann ist der Fehler 1. Art beschränkt durch* $\sup_{\theta_0 \in \Theta_0} E_{\theta_0}[\varphi(S)]$*, und der Fehler 2. Art durch* $\sup_{\theta_1 \in \Theta_1} E_{\theta_1}[1 - \varphi(S)]$.

Beweis. Für alle $\theta \in \Theta$ gilt $E_\theta[\varphi(S)] = P(\varphi(S) = 1)$. Das Ereignis $\{\varphi(S) = 1\}$ tritt ein genau dann, wenn man die Hypothese H_1 akzeptiert. Hieraus folgt die erste Aussage. Die zweite Aussage gilt, da $E_{\theta_1}[1 - \varphi(S)] = P_{\theta_1}(\varphi(S) = 0)$. □

Was macht einen guten Test aus? Folgende Definition gibt eine Antwort.

Definition 12.2. Sei $\varphi : \mathcal{X} \to \{0, 1\}$ eine Testfunktion zum Niveau α. Der Test $\varphi(S)$ ist ein *gleichmaßig bester Test zum Niveau* α, falls für alle Testfunktionen ψ zum Niveau α und alle $\theta \in \Theta_1$ gilt:

$$E_\theta[1 - \psi(S)] \geq E_\theta[1 - \varphi(S)]$$

(d.h. der Fehler 2. Art unter ψ ist mind so groß wie der unter φ).

Satz 12.3. *Sei $\Theta_0 = \{\theta_0\}$ und $\Theta_1 = \{\theta_1\}$ mit $0 < \theta_0 < \theta_1 < 1$. Weiterhin sei $d \in \mathcal{X}$ und*

$$\varphi(k) = \begin{cases} 1, & \text{falls } k > d, \\ 0, & \text{falls } k \leq d. \end{cases} \tag{12.3}$$

Falls $E_{\theta_0}[\varphi(S)] = \alpha$, dann ist φ ein gleichmäßig bester Test zum Niveau α.

Für den Beweis verwenden wir

Lemma 12.4. *Die Funktion*

$$g(k) := \frac{\mathcal{B}(n, \theta_1; k)}{\mathcal{B}(n, \theta_0; k)}, \qquad k \in \{0, 1, \ldots, n\},$$

ist monoton wachsend in k.

Beweis. Es gilt

$$g(k) = \frac{\binom{n}{k}\theta_1^k(1-\theta_1)^{n-k}}{\binom{n}{k}\theta_0^k(1-\theta_1)^{n-k}} = \left(\frac{\theta_1}{\theta_0}\right)^k \left(\frac{1-\theta_0}{1-\theta_1}\right)^k \left(\frac{1-\theta_1}{1-\theta_0}\right)^n.$$

Da $\frac{\theta_1}{\theta_0} > 1$ und $\frac{1-\theta_0}{1-\theta_1} > 1$, folgt die Behauptung. □

Beweis von Satz 12.3. Sei ψ ein Test mit $E_{\theta_0}\psi(S) \leq \alpha$ (d.h. der Fehler 1. Art von ψ ist $\leq \alpha$.) Es ist zu zeigen, dass

$$E_{\theta_1}[1 - \psi(S)] \geq E_{\theta_1}[1 - \varphi(S)] \tag{12.4}$$

(d.h. ψ hat einen mind. so großen Fehler 2. Art wie φ).

Da g monoton wachsend ist, existiert ein $c \in [0, \infty)$, sodass

$$\varphi(k) = \begin{cases} 1, & \text{falls } g(k) > c, \\ 0, & \text{falls } g(k) \leq c. \end{cases}$$

Wir definieren nun

$$f(k) := (\mathcal{B}(n, \theta_1; k) - c\,\mathcal{B}(n, \theta_0; k))\,(\varphi(k) - \psi(k)).$$

Die beiden Faktoren sind jeweils ≥ 0, falls $g(k) > c$; und die beiden Faktoren sind jeweils ≤ 0, falls $g(k) \leq c$. Somit ist die Funktion f nicht-negativ, dh $f \geq 0$. Wir erhalten weiter

$$\begin{aligned} 0 \leq \sum_{k=0}^{n} f(k) &= \sum_{k=0}^{n} \mathcal{B}(n, \theta_1; k)(\varphi(k) - \psi(k)) - c\sum_{k=0}^{n} \mathcal{B}(n, \theta_0; k))(\varphi(k) - \psi(k)) \\ &= E_{\theta_1}[\varphi(S)] - E_{\theta_1}[\psi(S)] - c(E_{\theta_0}[\varphi(S)] - E_{\theta_0}[\psi(S)]). \end{aligned} \tag{12.5}$$

Da $E_{\theta_0}\psi(S) \leq \alpha$ und $E_{\theta_0}\varphi(S) = \alpha$, gilt $c(E_{\theta_0}[\varphi(S)] - E_{\theta_0}[\psi(S)]) \geq 0$. Aus (12.5) folgt somit

$$0 \leq E_{\theta_1}[\varphi(S)] - E_{\theta_1}[\psi(S)],$$

was äquivalent zu (12.4) ist. □

Es ist nicht für alle $\alpha \in (0,1)$ möglich, einen Test der Form (12.3) zu finden, bei dem der Fehler 1. Art exakt mit α übereinstimmt. Wie kann man für beliebige α einen gleichmäßig besten Test finden? Wir erweitern dazu die Menge der Testfunktionen auf die Menge der Abbildungen $\varphi : \mathcal{X} \to [0,1]$. Eine Testfunktion, die nicht nur die Werte 0 und 1 annimmt, heißt randomisierte Testfunktion. Interpretation:

> $\varphi(S) = c \in (0,1)$ bedeutet: es wird eine Münze geworfen, die Kopf zeigt mit Wahrscheinlichkeit c, und Zahl mit $1-c$. Falls Kopf erscheint, wird H_1 akzeptiert; falls Zahl erscheint, wird an H_0 festgehalten.

Beachte: Lemma 12.1 gilt auch für randomisierte Tests. Somit können wir die Definition 12.2 direkt auf die Klasse der randomisierten Tests erweitern.

Der folgende Satz beschreibt nun für einelementige Hypothesen einen gleichmäßig besten Test. Für den Satz benötigen wir noch etwas Notation: sei F_{n,θ_0} die Verteilungsfunktion von $\mathcal{B}(n,\theta_0)$ (insbes. gilt dann $F_{n,\theta_0}(k) = \sum_{i=0}^{k} \mathcal{B}(n,\theta_0;i)$ für alle $k \in \mathcal{X}$).

Satz 12.5. *Sei $\Theta_0 = \{\theta_0\}$ und $\Theta_1 = \{\theta_1\}$ mit $0 < \theta_0 < \theta_1 < 1$. Weiterhin sei $\alpha \in (0,1)$ ein beliebiges Irrtumsniveau. Wir definieren nun die Testfunktion*

$$\varphi_\alpha(k) = \begin{cases} 1, & \textit{falls } k > d, \\ \gamma, & \textit{falls } k = d, \\ 0, & \textit{falls } k < d, \end{cases} \tag{12.6}$$

wobei

$$d := \min\{k \in \mathbb{Z} : F_{n,\theta_0}(k) \geq 1 - \alpha\}.$$

und

$$\gamma := \frac{F_{n,\theta_0}(d) - (1-\alpha)}{\mathcal{B}(n,\theta_0;d)}.$$

Dann ist $\varphi_\alpha(S)$ ein gleichmäßig bester Test zum Niveau α.

Beweis. Zunächst beachte: aus der Definition von d folgt

$$F_{n,\theta_0}(d-1) < 1-\alpha \leq F_{n,\theta_0}(d).$$

Weiterhin gilt $\gamma \in [0,1]$. Sei nun φ_α definiert wie in (12.6). Dann gilt

$$\begin{aligned} E_{\theta_0}[\varphi_\alpha(S)] &= \sum_{k>d} \mathcal{B}(n,\theta_0,k) + \gamma * \mathcal{B}(n,\theta_0;d) \\ &= 1 - F_{n,\theta_0}(d) + (F_{n,\theta_0}(d) - (1-\alpha) = \alpha. \end{aligned} \tag{12.7}$$

Also ist φ_α eine Testfunktion zum Niveau α.

Der Beweis, dass $\varphi_\alpha(S)$ ein gleichmäßig bester Test ist, ist identisch zu dem Beweis von Satz 12.3, wobei die Konstante $c = g(d)$ gesetzt werden muss. □

Die Aussage von Satz 12.5 gilt auch für Hypthesen mit $\Theta_0 = [0,\theta_0]$ und $\Theta_1 = (\theta_0, 1]$.

Satz 12.6. *Sei $\theta_0 \in (0,1)$. Dann ist der Test mit Testfunktion φ_α aus* (12.6) *auch ein gleichmäßig bester Test der Nullhypothese $\theta \in \Theta_0 = [0,\theta_0]$ gegen die Alternativhypothese $\theta \in \Theta_1 = (\theta_0, 1]$.*

Beweis. Die Abbildung $\theta \mapsto E_\theta[\varphi_\alpha(S)]$ ist monoton wachsend in θ. Aus (12.7) folgt somit, dass φ_α eine Testfunktion zum Niveau α ist.

Sei nun ψ eine beliebige Testfunktion zum Niveau α. Weiterhin sei $\theta_1 > \theta_0$. Aus Satz 12.5 folgt, dass $E_{\theta_1}[1-\psi(S)] \geq E_{\theta_1}[1-\varphi_\alpha(S)]$. Dies zeigt, dass φ_α ein glm bester Test ist. □

Bemerkung 12.7. In den Sätzen 12.3 und 12.5 wird $\theta_0 < \theta_1$ angenommen. Allerdings gelten analoge Aussagen im Fall $\theta_0 > \theta_1$. Falls $\theta_0 > \theta_1$, dann gibt es einen gleichmäßig besten Schätzer von der Form

$$\varphi_\alpha(k) = \begin{cases} 1, & \text{falls } k < d, \\ \gamma, & \text{falls } k = d, \\ 0, & \text{falls } k > d. \end{cases} \tag{12.8}$$

Ebenso, falls $\Theta_0 = [\theta_0, 1]$ und $\Theta_1 = [0,\theta_0)$, dann gibt es einen besten Schätzer der Form (12.8).

Beispiel 12.8. *Mit einem etablierten Impfstoff werden 80% der Geimpften von einer Krankheit X verschont. 80 Personen einer Testgruppe T werden mit einem neu entwickelten Impfstoff geimpft (und nicht mit dem Etablierten). Mit einem Test soll nun entschieden werden, ob der neue Impfstoff besser gegen die Krankheit X schützt.*

Fragen: a) Wie sollte man hier die Nullhypothese wählen? b) Stellen Sie einen besten Test zum Niveau 0.05 *auf. c) In der Testgruppe T bleiben 72 Personen von X verschont. Kann man die Nullhypothese zum Irrtumsniveau* 0.05 *ablehnen?*

Für die Beantwortung verwenden wir die Tabelle im Appendix C.

Antworten:

a) $H_0 : \theta \in [0, 0.8]$ *(neuer Impfstoff ist nicht besser). Begründung warum* $[0, 0.8]$ *und nicht das Komplement als Nullhypothese gewählt wird: Man möchte vermeiden, den etablierten Impfstoff durch einen schlechteren zu ersetzen.*

b) Wir wenden Satz 12.6 an. In diesem Beispiel gilt

$$d = \min\{k : F_{80,0.8}(k) \geq 0.95\} = 70,$$

und

$$\gamma = \frac{F_{80,0.8}(70) - 0,95}{\mathcal{B}(80, 0.8; 70)} = \frac{213}{277}.$$

Also ist der Test mit Testfunktion φ *definiert durch* $\varphi(k) = 1$ *für* $k \geq 71$, $\varphi(70) = \frac{213}{278}$ *und* $\varphi(k) = 0$ *für* $k < 70$, *ein bester Test.*

c) Ja.

A Tabelle der Normalverteilung

Tabelle der Normalverteilung

Tabelle des Integrals $\Phi(x) = \frac{1}{\sqrt{2\pi}} \int\limits_{-\infty}^{x} \mathrm{e}^{-t^2/2} dt$. Beispiel: $\Phi(1.23) = 0.8907$.

x	0	1	2	3	4	5	6	7	8	9
0.00	.5000	.5040	.5080	.5120	.5160	.5199	.5239	.5279	.5319	.5359
0.10	.5398	.5438	.5478	.5517	.5557	.5596	.5636	.5675	.5714	.5753
0.20	.5793	.5832	.5871	.5910	.5948	.5987	.6026	.6064	.6103	.6141
0.30	.6179	.6217	.6255	.6293	.6331	.6368	.6406	.6443	.6480	.6517
0.40	.6554	.6591	.6628	.6664	.6700	.6736	.6772	.6808	.6844	.6879
0.50	.6915	.6950	.6985	.7019	.7054	.7088	.7123	.7157	.7190	.7224
0.60	.7257	.7291	.7324	.7357	.7389	.7422	.7454	.7486	.7517	.7549
0.70	.7580	.7611	.7642	.7673	.7704	.7734	.7764	.7794	.7823	.7852
0.80	.7881	.7910	.7939	.7967	.7995	.8023	.8051	.8079	.8106	.8133
0.90	.8159	.8186	.8212	.8238	.8264	.8289	.8315	.8340	.8365	.8389
1.00	.8413	.8438	.8461	.8485	.8508	.8531	.8554	.8577	.8599	.8621
1.10	.8643	.8665	.8686	.8708	.8729	.8749	.8770	.8790	.8810	.8830
1.20	.8849	.8869	.8888	.8907	.8925	.8944	.8962	.8980	.8997	.9015
1.30	.9032	.9049	.9066	.9082	.9099	.9115	.9131	.9147	.9162	.9177
1.40	.9192	.9207	.9222	.9236	.9251	.9265	.9279	.9292	.9306	.9319
1.50	.9332	.9345	.9357	.9370	.9382	.9394	.9406	.9418	.9429	.9441
1.60	.9452	.9463	.9474	.9485	.9495	.9505	.9515	.9525	.9535	.9545
1.70	.9554	.9564	.9573	.9582	.9591	.9599	.9608	.9616	.9625	.9633
1.80	.9641	.9649	.9656	.9664	.9671	.9678	.9686	.9693	.9699	.9706
1.90	.9713	.9719	.9726	.9732	.9738	.9744	.9750	.9756	.9762	.9767
2.00	.9773	.9778	.9783	.9788	.9793	.9798	.9803	.9808	.9812	.9817
2.10	.9821	.9826	.9830	.9834	.9838	.9842	.9846	.9850	.9854	.9857
2.20	.9861	.9865	.9868	.9871	.9875	.9878	.9881	.9884	.9887	.9890
2.30	.9893	.9896	.9898	.9901	.9904	.9906	.9909	.9911	.9913	.9916
2.40	.9918	.9920	.9922	.9925	.9927	.9929	.9931	.9932	.9934	.9936
2.50	.9938	.9940	.9941	.9943	.9945	.9946	.9948	.9949	.9951	.9952
2.60	.9953	.9955	.9956	.9957	.9959	.9960	.9961	.9962	.9963	.9964
2.70	.9965	.9966	.9967	.9968	.9969	.9970	.9971	.9972	.9973	.9974
2.80	.9974	.9975	.9976	.9977	.9977	.9978	.9979	.9980	.9980	.9981
2.90	.9981	.9982	.9983	.9983	.9984	.9984	.9985	.9985	.9986	.9986

B Tabellen der Binomialverteilung

$n = 50$ und $p = 0.1$:

k	$\mathcal{B}(50, 0.1; k)$	$\sum_{i=0}^{k} \mathcal{B}(50, 0.1; i)$
0	0.005154	0.005154
1	0.028632	0.033786
2	0.077943	0.111729
3	0.138565	0.250294
4	0.180905	0.431198
5	0.184925	0.616123
6	0.154104	0.770227
7	0.107628	0.877855
8	0.064278	0.942133
9	0.033329	0.975462
10	0.015183	0.990645
11	0.006135	0.99678
12	0.002215	0.998995
13	0.000719	0.999715
14	0.000211	0.999926
15	0.000056	0.999983
16	0.000014	0.999996
17	0.000003	0.999999
18	0.000001	1.000000
19	0.000000	1.000000
$\vdots$	$\vdots$	$\vdots$
50	0.000000	1.000000

$n = 50$ und $p = 0.05$:

k	$\mathcal{B}(50, 0.05; k)$	$\sum_{i=0}^{k} \mathcal{B}(50, 0.05; i)$
0	0.076945	0.076945
1	0.202487	0.279432
2	0.261101	0.540533
3	0.219875	0.760408
4	0.135975	0.896383
5	0.065841	0.962224
6	0.02599	0.988214
7	0.008598	0.996812
8	0.002432	0.999244
9	0.000597	0.999841
10	0.000129	0.99997
11	0.000025	0.999995
12	0.000004	0.999999
13	0.000001	1.000000
14	0.00000	1.000000
$\vdots$	$\vdots$	$\vdots$
50	0.000001	1.000000

$n = 80$ und $p = 0.8$:

k	$\mathcal{B}(80, 0.8; k)$	$\sum_{i=0}^{k} \mathcal{B}(80, 0.8; i)$
0	0.0000	0.0000
1	0.0000	0.0000
$\vdots$	$\vdots$	$\vdots$
61	0.0745	0.2379
62	0.0913	0.3292
63	0.1044	0.4336
64	0.1109	0.5445
65	0.1092	0.6537
66	0.0993	0.7530
67	0.0830	0.8360
68	0.0634	0.8994
69	0.0441	0.9435
70	0.0277	0.9713
71	0.0156	0.9869
72	0.0078	0.9947
73	0.0034	0.9982
74	0.0013	0.9994
75	0.0004	0.9999
76	0.0001	1.0000
77	0.0000	1.0000
$\vdots$	$\vdots$	$\vdots$
80	0.0000	1.0000

Literatur

[1] Sheldon M Ross. *Introduction to probability models.* Academic press, 2014.